

Ecole Supérieur d'Informatique, de Management et de Télécommunication
SUP MIT

Cours d'analyse des données

Présenté par: Pr. *Abdelaziz QAFFOU*

2008/2009

Plan du cours

- **Chapitre 1: Les méthodes de l'analyse des données**
- **Chapitre 2: L'Analyse en Composantes Principales (ACP)**
- **Chapitre 3: L'Analyse Factorielle des Correspondances (AFC)**
- **Chapitre 4: L'Analyse des Correspondances Multiples (ACM)**
- **Chapitre 5: L'Analyse Factorielle Discriminante (AFD)**

Chapitre 1: Les méthodes de l'analyse des données

1. Introduction

- Les méthodes de l'analyse des données sont des méthodes statistiques multivariées qui sont essentiellement descriptives.
- Ces méthodes sont particulièrement utiles lorsque les tableaux de données à analyser sont de très grandes dimensions.
- L'objet de l'analyse des données est de découvrir la structure d'un ensemble de variables à travers des observations ou individus. Cette structure ne peut être connue directement du fait de la taille ou de la complexité des données mises en jeu.
- On représente les liens statistiques entre individus d'une part, entre variables d'autre part et même parfois entre individus et variables, pour aboutir à des représentations graphiques de ces liens entre les données.
- On fait appel à des méthodes et traitements spécifiques pour gérer, analyser puis synthétiser les données.

2. Les données statistiques

Les données sont un ensemble organisé d'information dont le point commun est la couverture d'un domaine précis en vue d'une action.

- ➔ Si le domaine est la qualité de service dans les télécommunications, on réunira toutes les informations susceptibles d'avoir une influence sur la qualité de service.
- ➔ Si le domaine est la description du réseau téléphonique, on réunira toutes les informations relatives à la description physique du réseau téléphonique.

Une donnée peut aussi mettre en jeu des éléments quantitatifs (mesures, ratios, notes,...) ou des éléments qualitatifs (caractères, modalités, noms, échelles,...).

Comme les données sont trop nombreuses ou trop complexes, on fait appel à une collection de méthodes mathématiques et de logiciels qui permettent de décortiquer les données et d'en faire des résumés soit numériques, soit graphiques.

3. Les étapes d'exploration des données

- ➔ Élaboration des données: acquisition automatique, enquêtes, sondages,...
- ➔ Saisie des données: ordinateur
- ➔ Gestion des données: mise à jour, création, vérification, codification, tri, fusion,...
- ➔ Analyse des données: univariée, bivariée, multivariée, factorielle, classification,...

4. Analyse Factorielle

- ➔ L'objet de l'analyse factorielle est de représenter individus et variables dans un plan.
- ➔ Des méthodes basées sur l'algèbre linéaire et le calcul matriciel appliquées au tableau de données permettent de produire des représentations graphiques, où les objets à décrire deviennent des points dans un plan.
- ➔ Selon le type des données, on aura différents types d'analyses factorielles:

➤ Analyse en Composantes Principales (ACP)

- ✓ L'objet de l'ACP est d'élaborer et de figurer géométriquement sur un plan les informations les plus diverses contenues dans un tableau (n,p) dont les lignes représentent n individus et les colonnes correspondent à p variables mesurées sur ces individus.
- ✓ Ce tableau peut être de très grande taille et les données étudiées peuvent être quantitatives et hétérogènes.
- ✓ Le but fondamental de la représentation géométrique est de fournir une image qui permet d'un seul coup d'œil de saisir rapidement l'ensemble des éléments présentés et de mettre en évidence certains faits essentiels.
- ✓ L'étude conduit également au calcul et à l'édition d'indices fournissant une aide d'interprétation des graphiques obtenus.

➤ Analyse Factorielle des Correspondances (AFC)

- ✓ Cette méthode est particulièrement bien adaptée pour l'étude des tableaux de contingence (tableaux donnant la répartition d'une population statistique selon deux caractères qualitatifs que l'on croise).
- ✓ Elle a été également largement utilisée pour l'analyse de très nombreux modèles de données (tableaux de taux, tableaux de notes, tableaux de mensurations, ...).

- ✓ L'originalité et la puissance de l'analyse des correspondances font de cette méthode le modèle de référence dans l'analyse des données.

➤ **Analyse des Correspondances Multiples (ACM)**

- ✓ Cette méthode s'applique lorsque le nombre des caractères étudiés est supérieur à 2. Elle consiste dans l'application de l'analyse factorielle des correspondances à des tableaux logiques.
- ✓ C'est une méthode très souple qui permet de traiter simultanément l'ensemble des variables observées que ces variables soient quantitatives ou qualitatives.
- ✓ Cette méthode admet de nombreux domaines d'application et permet l'analyse de tableaux de données mettant en jeu de nombreuses variables.
- ✓ Elle est particulièrement utile pour l'analyse des questionnaires.

➤ **Analyse Factorielle Discriminante (AFD)**

- ✓ L'AFD permet d'étudier le lien existant entre des variables quantitatives et un caractère qualitatif. Ce dernier permet de répartir la population statistique étudiée en plusieurs classes.

Les objectifs majeurs de cette méthode sont:

- ✓ Objectif descriptif: Essayer de voir comment les variables quantitatives considérées permettent de distinguer (discriminer) les différentes classes.
- ✓ Objectif prévisionnel: Prévoir la classe d'appartenance de nouveaux individus sur lesquels on a observé les mêmes variables quantitatives.

Chapitre 2: L'Analyse en Composantes Principales (ACP)

1. Objectifs de l'ACP

- ➔ Analyser et résumer l'information contenue dans un tableau de données de types (individus x variables). Les variables étant quantitatives et pouvant être de différentes unités de mesures.
- ➔ Remplacer les variables initiales par un nombre plus petit de variable composées ou facteurs.
- ➔ L'ACP permet d'explorer les liaisons entre variables et les ressemblances entre individus.

☐ Visualisation des individus (Notion de distances entre individus):

Le but est d'évaluer leurs ressemblances et d'analyser les similitudes de leurs comportements vis-à-vis de l'ensemble des variables. Il s'agit de répondre aux questions suivantes:

- ✓ Quels sont les individus qui se ressemblent? Quels sont ceux qui diffèrent?
- ✓ Peut-on mettre en évidence des groupes homogènes d'individus?
- ✓ Peut-on définir une typologie des individus?

☐ Visualisation des variables (en fonction de leurs corrélations):

On essaye d'analyser leur liaison qui est mesurée en ACP en terme de corrélation et de répondre aux questions suivantes:

- ✓ Quelles sont les variables qui sont corrélées positivement?
- ✓ Quelles sont les variables qui s'opposent?
- ✓ Existe-il des groupes de variables corrélées entre elles?
- ✓ Peut-on faire une typologie des variables?
- ✓ Peut-on résumer l'ensemble des variables par un petit nombre de variables synthétiques appelées ***composantes principales***?
- ✓ Une composante principale peut être le représentant des groupes de variables liées entre elles.

❑ Interprétation des résultats


- ✓ Mesurer la qualité des représentations obtenus: critère globale et critères individuels
- ✓ Donner des noms aux axes: Expliquer la position des individus
- ✓ Utilisation éventuelle de variables supplémentaires (illustratives)


2. *Les données*

❑ Tableau de données

p variables quantitatives observées sur n individus

	X_1	X_2	...	X_j	...	X_p
1	x_{11}	x_{12}	...	x_{1j}	...	x_{1p}
2	x_{21}	x_{22}	...	x_{2j}	...	x_{2p}
.	.	.	...	.	...	.
i	x_{i1}	x_{i2}	...	x_{ij}	...	x_{ip}
.	.	.	...	.	...	.
n	x_{n1}	x_{n2}	...	x_{nj}	...	x_{np}

 Individu e_i



 Variable X_j

INDIVIDU = élément de $\mathbb{R}^p$

VARIABLE = élément de $\mathbb{R}^n$

❑ On cherche à représenter le nuage des individus

A chaque individu e_i on peut associer un point dans $\mathbb{R}^p$ = espace des individus




A chaque variable du tableau X est associée un axe de $\mathbb{R}^p$

Impossible à visualiser dès que $p > 3$

3. *Principe de l'ACP*

- ➔ On cherche une représentation des n individus $e_1, e_2, \dots, e_n$, dans un sous-espace F_k de $\mathbb{R}^p$ de dimension k (k petit = 2, 3, ...), (par exemple un plan).
- ➔ Autrement dit, on cherche à définir k nouvelles variables combinaisons linéaires des p variables initiales qui feront perdre le moins d'**information** possible.
- ✓ Ces variables seront appelées: **composantes principales**
- ✓ Les axes qu'elles déterminent: **axes principaux**
- ✓ Les formes linéaires associées: **facteurs principaux**



Variables:

X_1, X_2, X_3

X_4, X_5, X_6

X_7, X_8, X_9



Facteurs :

F_1

F_2

F_3

Par exemple: les variables X_i sont les caractéristiques d'une automobile, et les facteurs F_i les dimensions de perception comme la puissance, la beauté ou le confort.


- 1) F_k devra être ajusté le mieux possible au nuage des e_i : la somme des carrés des distances des e_i à F_k doit être minimale.



- 2) F_k est le sous-espace tel que le nuage projeté ait une inertie (dispersion) maximale.

➔ 1) et 2) sont basés sur les notions de: distance et projection orthogonale

4. Le choix de la distance entre individus



Dans le plan:

$$d^2(A, B) = (x_B - x_A)^2 + (y_B - y_A)^2$$

Dans l'espace $\mathbb{R}^p$ à p dimensions, on généralise cette notion: la distance euclidienne entre deux individus s'écrit:

$$d^2(e_i, e_j) = \sum_{k=1}^p (x_i^k - x_j^k)^2$$

Le problème qui se pose est le problème des unités de mesures!

Pour résoudre ce problème, on choisit de transformer les données en données centrées - réduites.

L'observation x_{ik} est remplacée par : $\frac{x_{ik} - \bar{x}_k}{s_k}$

Où: $\bar{x}_k$ = moyenne de la variable X_k

s_k = écart-type de la variable X_k

5. Inertie totale (Information totale)

➔ Les lignes d'un tableau de données X forment un nuage de points: $N = \{e_1, \dots, e_n\}$

$$G = \frac{1}{n} \sum_{i=1}^n e_i$$

→ Le centre de gravité de ce nuage de points est:

→ L'inertie totale du nuage est:

$$I_G = \sum_{i=1}^n \frac{1}{n} d^2(e_i, G)$$

L'axe qui s'ajuste bien au nuage de points passe par le centre de gravité G.

Les axes factoriels seront les vecteurs propres de la matrice centrée réduite (ACP Normée).

→ L'inertie mesure la dispersion totale du nuage de points, l'inertie est donc aussi égale à la somme des variances des variables étudiées.

→ En notant V la matrice de variances-covariances:


$$V = \begin{pmatrix} s_1^2 & s_{12} & \cdot & \cdot & s_{1p} \\ s_{21} & s_2^2 & \cdot & \cdot & s_{2p} \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ s_{p1} & s_{p2} & \cdot & \cdot & s_p^2 \end{pmatrix}$$

Alors
$$I_G = \sum_{i=1}^p s_i^2 \quad \text{et} \quad I_G = \text{Tr}(V)$$

→ Dans le cas où les variables sont centrées réduites, la variance de chaque variable vaut 1.

→ L'inertie totale est alors égale à p (nombre de variables).

6. Problème posé



Soit F un sous-ensemble de $\mathbb{R}^p$, f_i la projection orthogonale de e_i sur F.

On va chercher F tel que: $\sum_{i=1}^n \frac{1}{n} d^2(e_i, f_i)$ soit minimale.

Ce qui revient d'après le théorème de Pythagore à maximiser: $\sum_{i=1}^n \frac{1}{n} d^2(f_i, G)$

(maximiser l'inertie du nuage projeté)

7. La solution du problème posé

- ➔ La recherche d'axes portant le maximum d'inertie équivaut à la construction de nouvelles variables (auxquelles sont associées ces axes) de variance maximale.
- ➔ En d'autres termes, on effectue un changement de repère dans IR^p de façon à se placer dans un nouveau système de représentation où le premier axe apporte le plus possible de l'inertie totale du nuage, le deuxième axe le plus possible de l'inertie non prise en compte par le premier axe, et ainsi de suite.
- ➔ Cette réorganisation s'appuie sur la **diagonalisation** de la matrice de variances - covariances.

❑ Axes principaux

- ✓ On appelle axes principaux d'inertie les axes de direction des **vecteurs propres** de V normés à 1. Il y en a p.
- ✓ Le premier axe est celui associé à la plus grande valeur propre v_1 . On le note u_1 .
- ✓ Le deuxième axe est celui associé à la deuxième valeur propre v_2 . On le note u_2 .

❑ Composantes principales

- ✓ À chaque axe est associé une variable appelée composante principale.
- ✓ La composante C_1 est le vecteur renfermant les coordonnées des projections des individus sur l'axe 1.
- ✓ La composante C_2 est le vecteur renfermant les coordonnées des projections des individus sur l'axe 2.
- ✓ Pour obtenir ces coordonnées, on écrit que chaque composante principale est une combinaison linéaire des variables initiales.

❑ Propriétés des composantes principales

- ✓ **La variance d'une composante principale** est égale à **l'inertie apportée par l'axe principal** qui lui est associé:

$$Var(C_1) = v_1 \quad \text{et} \quad Var(C_2) = v_2$$

- ✓ **Les composantes principales sont non corrélées deux à deux**: en effet les axes associés sont orthogonaux.


8. Représentation des individus

La $j^{\text{ème}}$ composante principale:

$$C_j = \begin{pmatrix} c_1^j \\ c_2^j \\ \vdots \\ c_n^j \end{pmatrix}$$


fournit les coordonnées des n individus sur le $j^{\text{ème}}$ axe principal.

Si on désire une représentation plane des individus, la meilleur sera celle réalisée grâce aux deux premières composantes principales.



9. Représentation des variables

Les proximités entre les composantes principales et les variables initiales sont mesurées par les covariances, et surtout les corrélations.




$r(C_j, X_j)$ est le coefficient de corrélation linéaire entre C_j et X_j

10. Les aides d'interprétation

■ Interprétation des proximités entre variables

On utilise le coefficient de corrélation: $r(X_i, X_j) = \cos(X_i, X_j)$



X1 et X2 : fortement corrélés positivement
 X1 et X4 : fortement corrélés négativement
 X1 et X3 : très faiblement corrélés

Sur le plan de projection, les points les plus proches du cercle unité sont ceux qui ont une plus grande qualité de représentation.

■ Critère global


$$\frac{v_i}{v_1 + v_2 + \dots + v_p} \quad \text{Mesure la part d'inertie expliquée par l'axe } i.$$

$$\frac{v_1 + v_2}{v_1 + v_2 + \dots + v_p} \quad \text{Mesure la part d'inertie expliquée par le premier plan principal.}$$

Ce critère (souvent exprimé en pourcentage) mesure le degré de reconstitution des carrés des distances.

■ Critère individuel

- Pour chaque individu e_i , la qualité de sa représentation est définie par le carré du cosinus de l'angle entre l'axe de projection et le vecteur e_i .
- En général, les qualités de représentation sont données axe par axe.



$$\cos^2 \theta = \cos^2 \theta_1 + \cos^2 \theta_2$$

Pour avoir la qualité de représentation dans un plan, on additionne les critères correspondant aux axes étudiés.

Ce critère n'a pas de signification pour les individus proches de G.

■ Contributions

Il est très utile aussi de calculer pour chaque axe la contribution apportée par les divers individus à cet axe.

Considérons la $k^{\text{ème}}$ composante principale C_k , soit C_{ik} la valeur de la composante pour le $i^{\text{ème}}$ individu.

$$\sum_{i=1}^n \frac{1}{n} C_{ik}^2 = v_k$$

La contribution de l'individu e_i à la $k^{\text{ème}}$ composante est définie par: $\frac{\frac{1}{n} C_{ik}^2}{v_k}$

■ Remarque

Il n'est pas souhaitable qu'un individu ait une contribution excessive (car facteur d'instabilité), donc éliminer les individus dont la contribution est trop importante.

Pratique de l'Analyse en Composante principale (ACP) sous SPSS

1) Introduction

L'analyse en composante principale (ACP) est une technique exploratoire pour résumer les relations entre les variables à l'aide d'un jeu de facteurs aussi réduit que possible.

Outre l'aspect réduction des données, ce groupe de facteurs est sensé discriminer les données de manière à être facilement interprétable. Cette technique est très utilisée en évaluation des préférences individuelles, lors de l'identification de sous-groupe homogènes (dans le sens où ils partagent les mêmes facteurs), etc...

L'ACP est une technique statistique dont le but est de représenter les relations qui lient les variables au travers des valeurs prises par un échantillon d'individus. Un des aspects de l'étude est alors de résumer l'ensemble des variables en un petit nombre de variables synthétiques appelées facteurs.

2) 1.2 les données

IGQS: Indice global de la qualité de service obtenu à partir des 6 autres;

IZAA: Mesure de l'efficacité en ce qui concerne les appels dans la région;

EZAA: Mesure de l'efficacité en ce qui concerne les appels entre régions;

TSI: Taux de signalisation des dérangements;

VR2: Vitesse de réparation des dérangements;

TCR: Taux d'efficacité du service des renseignements;

TCOM: Temps d'établissement des communications.

région	IGQS	IZAA	EZAA	TSI	VR2	TCR	TCOM
Amiens	89,1	66,3	66,2	28	83,9	68	18,7
Besançon	95,7	69,5	68	19	87,5	68,3	15,2
Bordeaux	89,3	67,2	66,1	29,2	84,6	70,6	15,9
Caen	88	67,1	66,6	31,5	82,9	74,1	15,6
Châlons	95,8	67,9	68,1	22,5	93,4	78,9	16,6
Clermont	96	70,8	69,3	22,5	87,5	75,6	16,6
Dijon	93,4	68,1	68,3	23,2	86,7	74,6	16,1
Lille	91,8	67,1	67,1	28,5	90,2	58,5	16,3
Limoges	83,4	66,7	64,7	38,6	78,9	66,4	15,5
Lyon	93,5	67,4	68,4	21,2	86,1	67,8	17,3
Marseill	87,1	64	63,9	29,7	86,3	54,4	16,2
Montpell	89,3	66,3	64,7	27,6	85,9	60,7	15,5
Nancy	93,8	67,6	68,9	25,4	89,7	73,1	16,6
Nantes	91,8	67,8	67,8	28,9	88,3	74,3	16,7
Orléans	92,7	67,6	67	25,7	89	70,2	18,5
Poitiers	90,2	67,7	66,8	28,5	84,3	74,2	16,3
Rennes	91,5	68,3	67,9	28,1	85,5	66,2	17,3
Rouen	87,4	68,1	67,8	31,5	78,7	71,3	15,1
Strasbou	97,8	67,9	70,1	18,8	93,5	82	15,8
Toulouse	88	67,6	66,9	30,5	80,3	70,2	16,2
Paris	98,2	66,6	68,4	23,2	89,8	54,1	17,1

L'ACP travaille sur des tableaux du type individus x variables. Par conséquent, les données traitées en ACP sont de nature continue.

Les objets manipulés par l'ACP sont les individus ainsi que les variables. La façon dont on aborde les deux est différente. On examine les deux selon leurs ressemblances (ou leurs dissemblances) afin de déterminer une typologie; et on examine les variables à travers les corrélations qui les relient positivement ou négativement.

SPSS propose un large éventail de méthodes, reposant sur des hypothèses statistiques des distributions des données, d'autres étant purement géométriques et ne reposant pas sur la distribution des données, d'autres étant purement géométriques et ne reposant pas sur la nature des variables.




TP-ACP - Editeur de données SPSS																																																																																																																																																																																																																																					
Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide																																																																																																																																																																																																																																					
7: <table> <tr> <th></th><th>region</th><th>igqs</th><th>izaa</th><th></th><th></th><th></th><th></th><th></th><th></th></tr> <tr><td>1</td><td>Amiens</td><td>89.1</td><td>66.3</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>2</td><td>Besançon</td><td>95.7</td><td>69.5</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>3</td><td>Bordeaux</td><td>89.3</td><td>67.2</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>4</td><td>Caen</td><td>88.0</td><td>67.1</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>5</td><td>Châlons</td><td>95.8</td><td>67.9</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>6</td><td>Clermont</td><td>96.0</td><td>70.8</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>7</td><td>Dijon</td><td>93.4</td><td>68.1</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>8</td><td>Lille</td><td>91.8</td><td>67.1</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>9</td><td>Limoges</td><td>83.4</td><td>66.7</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>10</td><td>Lyon</td><td>93.5</td><td>67.4</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>11</td><td>Marseill</td><td>87.1</td><td>64.0</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>12</td><td>Montpell</td><td>89.3</td><td>66.3</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>13</td><td>Nancy</td><td>93.8</td><td>67.6</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>14</td><td>Nantes</td><td>91.8</td><td>67.8</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>15</td><td>Orléans</td><td>92.7</td><td>67.6</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>16</td><td>Poitiers</td><td>90.2</td><td>67.7</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>17</td><td>Rennes</td><td>91.5</td><td>68.3</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>18</td><td>Rouen</td><td>87.4</td><td>68.1</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>19</td><td>Strasbou</td><td>97.8</td><td>67.9</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>20</td><td>Toulouse</td><td>88.0</td><td>67.6</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> <tr><td>21</td><td>Paris</td><td>98.2</td><td>66.6</td><td></td><td></td><td></td><td></td><td></td><td></td></tr> </table> Rapports Statistiques descriptives Tabuler Comparer les moyennes Modèle linéaire général Corrélation Régression Analyse log-linéaire Classification Factorisation Positionnement Tests non paramétriques Séries chronologiques Survie Réponses multiples Analyse factorielle... Analyse des correspondances... Codage optimal...											region	igqs	izaa							1	Amiens	89.1	66.3							2	Besançon	95.7	69.5							3	Bordeaux	89.3	67.2							4	Caen	88.0	67.1							5	Châlons	95.8	67.9							6	Clermont	96.0	70.8							7	Dijon	93.4	68.1							8	Lille	91.8	67.1							9	Limoges	83.4	66.7							10	Lyon	93.5	67.4							11	Marseill	87.1	64.0							12	Montpell	89.3	66.3							13	Nancy	93.8	67.6							14	Nantes	91.8	67.8							15	Orléans	92.7	67.6							16	Poitiers	90.2	67.7							17	Rennes	91.5	68.3							18	Rouen	87.4	68.1							19	Strasbou	97.8	67.9							20	Toulouse	88.0	67.6							21	Paris	98.2	66.6						
	region	igqs	izaa																																																																																																																																																																																																																																		
1	Amiens	89.1	66.3																																																																																																																																																																																																																																		
2	Besançon	95.7	69.5																																																																																																																																																																																																																																		
3	Bordeaux	89.3	67.2																																																																																																																																																																																																																																		
4	Caen	88.0	67.1																																																																																																																																																																																																																																		
5	Châlons	95.8	67.9																																																																																																																																																																																																																																		
6	Clermont	96.0	70.8																																																																																																																																																																																																																																		
7	Dijon	93.4	68.1																																																																																																																																																																																																																																		
8	Lille	91.8	67.1																																																																																																																																																																																																																																		
9	Limoges	83.4	66.7																																																																																																																																																																																																																																		
10	Lyon	93.5	67.4																																																																																																																																																																																																																																		
11	Marseill	87.1	64.0																																																																																																																																																																																																																																		
12	Montpell	89.3	66.3																																																																																																																																																																																																																																		
13	Nancy	93.8	67.6																																																																																																																																																																																																																																		
14	Nantes	91.8	67.8																																																																																																																																																																																																																																		
15	Orléans	92.7	67.6																																																																																																																																																																																																																																		
16	Poitiers	90.2	67.7																																																																																																																																																																																																																																		
17	Rennes	91.5	68.3																																																																																																																																																																																																																																		
18	Rouen	87.4	68.1																																																																																																																																																																																																																																		
19	Strasbou	97.8	67.9																																																																																																																																																																																																																																		
20	Toulouse	88.0	67.6																																																																																																																																																																																																																																		
21	Paris	98.2	66.6																																																																																																																																																																																																																																		
vr2 tcr tcom 83.9 68.0 18.7 87.5 68.3 15.2 84.6 70.6 15.9 82.9 74.1 15.6																																																																																																																																																																																																																																					
90.2 58.5 16.3 78.9 66.4 15.5 86.1 67.8 17.3 86.3 54.4 16.2 85.9 60.7 15.5 89.7 73.1 16.6 88.3 74.3 16.7 89.0 70.2 18.5 84.3 74.2 16.3 85.5 66.2 17.3 78.7 71.3 15.1 93.5 82.0 15.8 80.3 70.2 16.2 89.8 54.1 17.1																																																																																																																																																																																																																																					
Affichage des données Affichage des variables Facteur SPSS processeur est prêt																																																																																																																																																																																																																																					

3) Le modèle de base

a) Etude des liens entre les variables

➤ Statistiques descriptives

Après avoir défini les variables qui vont composer notre ACP, il est souvent utile de consulter des premières statistiques descriptives relatant le comportement des variables.



Statistiques descriptives

	Moyenne	Ecart-type	n analyse
IGQS	91.610	3.864	21
IZAA	67.505	1.299	21
EZAA	67.286	1.558	21
TSI	26.767	4.730	21
VR2	86.333	4.057	21
TCR	69.214	7.354	21
TCOM	16.433	.954	21

L'intérêt principal de ce type de statistiques est d'étudier la variabilité des quantités qui vont composer l'ACP.

➤ Étude des corrélations

Les corrélations entre les variables obtenues à partir du bouton *Caractéristiques* de la boîte de dialogue initiale, montrent leur degré d'interprétation dans le sens où elles peuvent partager des caractéristiques communes.

Matrice de corrélation

		IGQS	IZAA	EZAA	TSI	VR2	TCR	TCOM
Corrélation	IGQS	1.000	.489	.809	-.918	.829	.233	.224
	IZAA	.489	1.000	.717	-.435	.131	.601	-.094
	EZAA	.809	.717	1.000	-.706	.510	.549	.114
	TSI	-.918	-.435	-.706	1.000	-.744	-.252	-.179
	VR2	.829	.131	.510	-.744	1.000	.134	.261
	TCR	.233	.601	.549	-.252	.134	1.000	-.084
	TCOM	.224	-.094	.114	-.179	.261	-.084	1.000

Si les variables sont peu corrélées, il est alors inutile de chercher déterminer des facteurs communs, les variables partageant peu de caractéristiques communes.

➤ Critères de pertinence d'une ACP

Dans la lignée de l'étude des corrélations, SPSS vous propose deux tests permettant de juger de la pertinence d'une ACP sur un échantillon particulier.

Le test de Kaiser Meyer Olkin (KMO): vérifier que KMO est supérieur à 0,6 ou 0,5; pour avoir une analyse des facteurs très bonne. C'est un indice pour la mesure de la qualité d'échantillonnage.

Indice KMO

Mesure de précision de l'échantillonnage de Kaiser-Meyer-Olkin.	.574
---	------

b) Détermination des composantes principales

SPSS propose plusieurs techniques d'extractions de facteurs, la plus connue et la plus utilisées étant l'analyse en composantes principales. Cette méthode détermine les facteurs principaux en constituant des combinaisons linéaires non corrélées deux à deux des variables initiales.

La première composante principale est la combinaison linéaire de variables qui explique le mieux la variabilité de l'échantillon. Géométriquement, elle détermine la direction pour laquelle le nuage de points a son allongement (ou inertie) maximale.

La deuxième composante est la combinaison linéaire des variables qui explique le mieux la variance résiduelle. Sa direction est orthogonale à la précédente.

Analyse > factorisation > analyse factorielle > Extraction



Formellement, il est possible d'extraire autant de facteurs que de variables. Cependant, la méthode de construction des axes fait que les derniers ont un pouvoir explicatif très faible.

Qualité de représentation

	Initial	Extraction
IGQS	1.000	.954
IZAA	1.000	.804
EZAA	1.000	.867
TSI	1.000	.851
VR2	1.000	.800
TCR	1.000	.684
TCOM	1.000	.388

Variance expliquée totale

	Valeurs propres initiales			Sommes des carrés chargées		
Composante	Total	% de la variance ==	% cumulés	Total	% de la variance ==	% cumulés
1	3.821	54.585	54.585	3.821	54.585	54.585
2	1.527	21.809	76.394	1.527	21.809	76.394
3	.811	11.592	87.986			
4	.463	6.609	94.595			
5	.180	2.574	97.169			
6	.176	2.518	99.687			
7	2.194E-02	.313	100.000			

On déduit que l'analyse factorielle est essentielle dans notre étude à partir de 7 variables, on peut construire un espace de faible dimension sans perte d'information.

Pour chaque facteur, nous avons une valeur propre associée. La somme des 7 valeurs propres donne bien 7, qui correspond au nombre de facteur total. C'est également la trace de la matrice des corrélations i.e la somme des termes diagonaux de la matrice :

$$3,82+1,53+0,81+0,46+0,18+0,18+0,02 = 7$$

Nous avons donc décomposé l'inertie du nuage de points des coordonnées centrées réduites (représentée par la matrice des corrélations) en la projetant sur des directions orthogonales.

Nous rappelons que l'on cherche toujours à expliquer une variance totale et que chaque valeur propre contribue à expliquer un certain pourcentage.

Par exemple, le premier axe explique 54,58% de la variance totale. Si on se réfère aux pourcentage cumulés, on remarque que 87,98% de la variance totale est expliquée par les trois premiers axes.

Nous avons donc réussi sur 3 variables la presque totalité de la variabilité de l'échantillon.

Analyse factorielle : Extraction

Méthode : **Composantes principales**

☒ Analyser : Matrice de corrélation
☐ Matrice de covariance


☒ Afficher : Structure factorielle sans rotation
☒ Graphique des valeurs propres

☐ Extraire : Valeurs propres supérieures à : 1
☒ Nombre de facteurs : 2

Maximum des itérations pour converger : 25

Poursuivre
 Annuler
 Aide

Graphique des valeurs propres



D'après le graphique des valeurs propres, les facteurs possibles sont entre 3 et 5. Pour trois facteurs, on remarque que la qualité de représentation est faible (88% des informations).

Les coordonnées des variables sur les axes factoriels

Matrice des composantes

	Composant e	
	1	2
IGQS	.945	-.247
IZAA	.668	.598
EZAA	.907	.210
TSI	-.894	.229
VR2	.751	-.486
TCR	.507	.653
TCOM	.200	-.590

La qualité de représentation

	Initial	Extraction
IGQS	1.000	.954
IZAA	1.000	.804
EZAA	1.000	.867
TSI	1.000	.851
VR2	1.000	.800
TCR	1.000	.684
TCOM	1.000	.388

Par exemple, la qualité de représentation de la variable IGQS formée par les trois premiers axes est égale à :

$$0,976 = (0,945)^2 + (-0,247)^2 + (-0,147)^2$$

De la même façon vous pouvez décomposer les valeurs propres:

$$v_1=3,82 = (0,945)^2 + (0,668)^2 + \dots + (0,2)^2$$

SPSS n'affiche pas les contributions de chaque variable à l'inertie de chaque axe factoriel. Ceci étant, vous pouvez tout de même les recalculer en divisant le carré des coordonnées par chaque valeur propre, par exemple, pour $v_1 = 3,82$, nous aurons :

$$CTR(IGQS) = ((0,945)^2)/(3,82)$$

Le premier axe explique 77% de la variabilité du modèle. D'autre part, il explique une bonne partie des variables de notre modèle hormis les variables TCR, IZAA et TCOM.


c) Représentation des individus et des variables

➤ Représentation des variables





Diagramme de composantes



On a vu que le lien (la corrélation entre 2 variables) s'interprète en terme de l'angle que font ces 2 variables. Plus l'angle est petit plus la corrélation entre IZAA et EZAA est forte.

En ACP, il faut interpréter les variables en terme d'axes, ainsi, l'axe 1, signifie une grande valeur pour IGQS=945, EZAA=907, VR2=751, IZAA=668 et TSI=-894.

Donc cette nouvelle variable signifie « bonne qualité de service global ».

➤ Représentation des individus

TP-ACP - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

1: fac1_1 -0.564258001183128

Diagramme de dispersion...

	region	igqs	izaa	ezaa	tcr	tcom	fac1_1	fac2_1
1	Amiens	89.1	66.3		68.0	18.7	-.56426	-1.11291
2	Besançon	95.7	69.5		68.3	15.2	.99539	.60220
3	Bordeaux	89.3	67.2		70.6	15.9	-.57803	.40988
4	Caen	88.0	67.1		74.1	15.6	-.74795	1.01004
5	Châlons	95.8	67.9		78.9	16.6	1.18255	-.17860
6	Clermont	96.0	70.8		75.6	16.6	1.42328	1.06560
7	Dijon	93.4	68.1		74.6	16.1	.62214	.50077
8	Lille	91.8	67.1		58.5	16.3	-.16964	-.96466
9	Limoges	83.4	66.7		66.4	15.5	-2.07478	1.04585
10	Lyon	93.5	67.4		67.8	17.3	.56267	-.60379
11	Marseill	87.1	64.0		54.4	16.2	-1.70291	-1.83988
12	Montpell	89.3	66.3		60.7	15.5	-.97098	-.55240
13	Nancy	93.8	67.6		73.1	16.6	.70878	-.06942
14	Nantes	91.8	67.8		74.3	16.7	.22647	.22770
15	Orléans	92.7	67.6	67.0	70.2	18.5	.35244	-1.06523
16	Poitiers	90.2	67.7	66.8	74.2	16.3	-.23947	.63377
17	Rennes	91.5	68.3	67.9	66.2	17.3	.08063	-.11978
18	Rouen	87.4	68.1	67.8	71.3	15.1	-.75039	1.81257
19	Strasbou	97.8	67.9	70.1	82.0	15.8	1.81487	.29372
20	Toulouse	88.0	67.6	66.9	70.2	16.2	-.74879	.89001
21	Paris	98.2	66.6	68.4	54.1	17.1	.57797	-1.98545

TP-ACP - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide



1: fac1_1 -0.564258001183128



Diagramme de dispersion

Simple Matrice Superposé 3D

Définir Annuler Aide

	region	igqs	izaa	ezaa	tsi	vr2	tcr	tcom	fac1_1	fac2_1
1	Amiens	89.1	66.3	66.2	28.0	83.9	68.0	18.7	-.56426	-1.11291
2	Besançon	95.7	69.5	68.0	19.0	87.5	68.3	15.2	.99539	.60220
3	Bordeaux	89.3	67.2	66.1	29.2	84.6	70.6	15.9	-.57803	.40988
4	Caen	88.0	67.1	66.6	31.5	82.9	74.1	15.6	-.74795	1.01004
5	Châlons	95.8	67.9	68.1	22.5	93.4	78.9	16.6	1.18255	-.17860
6	Clermont	96.0	70.8	69.3	22.5	87.5	75.6	16.6	1.42328	1.06560
7	Dijon	93.4	68.1	68.3	23.2	86.7	74.6	16.1	.62214	.50077
8	Lille	91.8	67.1	67.1	28.5	90.2	58.5	16.3	-.16964	-.96466
9	Limoges	83.4	66.7	64.7	38.6	78.9	66.4	15.5	-2.07478	1.04585
10	Lyon	93.5	67.4	68.4	21.2	86.1	67.8	17.3	.56267	-.60379
11	Marseill	87.1	64.0	63.9					-1.70291	-1.83988
12	Montpell	89.3	66.3	64.7					-.97098	-.55240
13	Nancy	93.8	67.6	68.9					.70878	-.06942
14	Nantes	91.8	67.8	67.8					.22647	.22770
15	Orléans	92.7	67.6	67.0					.35244	-1.06523
16	Poitiers	90.2	67.7	66.8					-.23947	.63377
17	Rennes	91.5	68.3	67.9					.08063	-.11978
18	Rouen	87.4	68.1	67.8	31.5	78.7	71.3	15.1	-.75039	1.81257
19	Strasbou	97.8	67.9	70.1	18.8	93.5	82.0	15.8	1.81487	.29372
20	Toulouse	88.0	67.6	66.9	30.5	80.3	70.2	16.2	-.74879	.89001
21	Paris	98.2	66.6	68.4	23.2	89.8	54.1	17.1	.57797	-1.98545





Contrairement au nuage des variables, celui des individus est bien réparti autour de l'origine qui est son centre de gravité. La proximité entre deux individus signifie une qualité de service globalement similaire.

Les individus qui sont proche du centre de gravité, soient qu'ils admettent un comportement moyen, soient qu'ils aient une mauvaise qualité sur ce plan.

Les points individus qui sont éloignés de l'origine vont avoir un comportement particulier et vont devoir jouer un rôle intéressant dans l'analyse.

➤ Interprétation des résultats obtenus

On peut noter que les variables fortement corrélées positivement {IGQS, VR2, EZAA}. On peut noter que les variables fortement corrélées négativement TSI avec le groupe précédent.

L'inertie total est $p=7$ (=sigma des val propres), dans un premier temps on retient les axes tel que: val propre > 1 , qui est la valeur moyenne. Nous obtenons des résultats exceptionnels, le 1er axe explique 54,58% de l'inertie, le 2ème explique 21,80% et le 1er plan explique plus de $\frac{3}{4}$ de l'inertie total. Notre analyse se limitera au 1er plan factoriel, mais pour une analyse plus fine, on peut utiliser le plan (1,3) qui va expliquer plus de 66% de l'inertie.

Toutes les variables sont bien représentées sauf TCOM. Tous les individus sont bien représentés sauf Nantes et Rennes, c'est pourquoi ils se situent au centre du graphique.

Le 1er axe factoriel est un axe de qualité globale du service, opposant les régions de bonnes qualités de services aux régions de mauvaises qualités de services. Le 2ème axe va nous permettre de différencier entre deux régions ayant la même qualité de service globale.

TP n°1 – ACP : Notes des élèves

A un examen, les élèves sont notés sur n matières ; le profil de chaque élève peut donc être représenté par un point dans un espace à n dimensions. Mais il est difficile de visualiser les choses dans un espace de plus de 3 dimensions. On va donc par des projections se ramener à un espace à deux dimensions (représentation dans un plan). Ces axes de projections vont être choisis de façon à ce que la perte d'information soit minimale.

Ce qui intéresse en ACP, ce ne sont pas les valeurs absolues des variables (ici les notes) mais les différences relatives entre les individus. On va donc projeter sur les axes non pas les variables elles-mêmes mais les variables centrées réduites (en retranchant la moyenne et en divisant par l'écart-type). Autrement dit, on neutralise ainsi les différences dans les échelles de notation qu'il peut y avoir entre les disciplines.

Un raisonnement mathématique qui dépasse le cadre de cette courte note montre que les axes de projection permettent de conserver le maximum d'information sont obtenus par les coordonnées des vecteurs propres de la matrice des coefficients de corrélation entre les variables.

Les valeurs propres associées à ces vecteurs propres permettent de mesurer la part de variance expliquée par chaque axe.

Premier exemple avec 4 variables :

Elève	Maths	Français	His&Geo	Physique
A	10	5	8	10
B	15	4	4	14
C	8	9	4	8
D	9	15	12	9
E	19	12	13	18
F	2	8	15	3
G	14	10	14	14
H	5	8	6	6
I	4	3	7	5
J	8	12	3	8
K	2	4	2	3
L	1	3	4	4

Le traitement de ce tableau peut être fait sous le logiciel SPSS (Statistical Package for Social Science) qui permet d'appliquer la méthode ACP.

Résultats :

1) Matrice de corrélation

	MAT HS	FRANÇA IS	HISGE O	PHYSIQU E
MATHS	1	,432	,340	,993
FRANÇAIS	,432	1	,488	,405
HISGEO	,340	,488	1	,350


PHYSIQUE	,993	,405	,350	1
E				

2) Valeurs propres

Composante	Valeurs propres	% de la variance	% cumulés
1	2,546	63,660	63,660
2	,941	23,514	87,174
3	,507	12,678	99,852
4	5,922E-03	,148	100,000

Ce tableau signifie que la première composante principale C_1 permet d'expliquer 63,66% de la variance totale du nuage de points, que la seconde composante principale C_2 permet d'expliquer 23,51% de la variance totale. En projetant donc chaque individu sur le premier plan principal (C_1 , C_2), on conserve donc (63,66+23,51)% soit 87,17% de la variance totale (on a donc une bonne qualité de représentation).

3) Représentation graphique des variables




Ce graphique donne la représentation des variables dans le plan. Les points physique et maths sont très proches car les 2 variables sont très corrélées. Ces deux points sont très proches du cercle ce qui signifie que les 2 variables (maths et physiques) sont très bien représentées).

Les points hisgeo et français (sont proches) : corrélation positive entre les matières (un peu plus éloignés du cercle) donc moins bien représentées.

Sur le premier axe (axe horizontal qui contient 63% de l'information) les 4 variables ont des coordonnées positives. Ce premier axe est donc représentatif du niveau des élèves (les bons à droite, les mauvais à gauche).

Sur le second axe (axe vertical qui contient 23% de l'information) s'opposent plutôt les littéraires (en haut) et les scientifiques (en bas).

4) Représentation graphique des individus



La position des candidats sur le cercle permet d'interpréter facilement leur profil et ce d'autant qu'ils sont plus proches du cercle.

E bon en maths et physique, G moins bon en maths et physique mais un peu plus littéraire.

A l'opposé K et L mauvais en tout, B bon en sciences mais pas du tout littéraire à l'inverse de D.

TP n°2 – ACP : WISC

On a rassemblé les résultats de 15 enfants de 10 ans à 6 subtests du WISC (scores 0 à 5). Les variables observées sont : CUB (Cubes de Kohs), PUZ (Assemblage d'objets), CAL (Calcul mental), MEM (Mémoire immédiate des chiffres), COM (Compréhension de phrases), VOC (Vocabulaire). Le protocole observé est le suivant :

WISC	CUB	PUZ	CAL	MEM	COM	VOC
I1	5	5	4	0	1	1
I2	4	3	3	2	2	1
I3	2	1	2	3	2	2
I4	5	3	5	3	4	3
I5	4	4	3	2	3	2
I6	2	0	1	3	1	1
I7	3	3	4	2	4	4
I8	1	2	1	4	3	3
I9	0	1	0	3	1	0
I10	2	0	1	3	1	0
I11	1	2	1	1	0	1
I12	4	2	4	2	1	2
I13	3	2	3	3	2	3
I14	1	0	0	3	2	2
I15	2	1	1	2	3	2

On traite ces données par une analyse en composantes principales normée. Les principaux résultats de cette ACP sont indiqués ci-dessous :

Statistiques descriptives

	Moyenn e	Ecart- type	n analyse
CUB	2.60	1.55	15
PUZ	1.93	1.49	15
CAL	2.20	1.61	15
MEM	2.40	.99	15
COM	2.00	1.20	15
VOC	1.80	1.15	15

Matrice de corrélation

	CUB	PUZ	CAL	MEM	COM	VOC
CUB	1.000	.732	.921	-.449	.309	.273
PUZ	.732	1.000	.751	-.614	.281	.285
CAL	.921	.751	1.000	-.369	.408	.487
MEM	-.449	-.614	-.369	1.000	.303	.202
COM	.309	.281	.408	.303	1.000	.782
VOC	.273	.285	.487	.202	.782	1.000

Les corrélations les plus fortes sont celles correspondant aux coefficients de corrélation les plus proches de 1 ou -1. Ici, le coefficient de corrélation dont la valeur absolue est la plus proche de 1 est celui qui relie CUB et CAL.

La plupart des coefficients de corrélation sont positifs. Autrement dit, un bon résultat à un test est, en règle général, lié à de bons résultats aux autres tests. On note toutefois une exception remarquable : la variable MEM (mémoire immédiate des chiffres) est corrélée négativement à 3 autres variables : CUB, PUZ et CAL. Mais ce sont les seuls coefficients négatifs du tableau.

Indice KMO

KMO	0.572
------------	--------------

Qualité de representation

	Extraction
CUB	.845
PUZ	.832
CAL	.896
MEM	.816
COM	.871
VOC	.835


Variance expliquée totale

	Valeurs propres initiales			Sommes des carrés chargées		
Composante	Total	% de la variance ==	% cumulés	Total	% de la variance ==	% cumulés
1	3.258	54.302	54.302	3.258	54.302	54.302
2	1.837	30.619	84.921	1.837	30.619	84.921
3	.443	7.383	92.304			
4	.254	4.229	96.534			
5	.168	2.799	99.333			
6	4.004E-02	.667	100.000			

La somme des valeurs propres est égale à 6. Dans le cas d'une ACP normée telle que celle qui est effectuée ici, cette somme est égale au nombre de variables. Cette valeur correspond également à la variance du nuage des individus.

On peut choisir de ne s'intéresser qu'aux valeurs propres dont la contribution à la variance est supérieure à la moyenne. Ceci revient à étudier les composantes principales correspondant à des valeurs propres supérieures à 1. Or, seules les deux premières valeurs propres vérifient cette propriété sur l'exemple fourni.

Représentation des variables




Les extrémités des vecteurs représentant les variables sont toutes très proches du cercle des corrélations, ce qui montre que les qualités de représentation des variables sont satisfaisantes. D'autre part la dernière colonne du tableau des résultats relatifs aux variables montre que la variable la plus mal représentée est MEM, avec une qualité qui atteint quand même 0,816.

Les corrélations peuvent être lues sur le dessin ou sur le tableau des saturations. Seule la variable MEM est corrélée positivement avec le premier axe, toutes les autres sont corrélées négativement. Ainsi, cet axe oppose le résultat au test MEM à tous les autres tests.

Les corrélations les plus fortes sont observées pour les variables MEM, COM et VOC. Ces variables sont toutes trois corrélées négativement avec la variable CP2.

Représentation des individus



Le sujet le mieux représenté est I1, le mal représenté est I15 (*il est proche de l'origine des axes*). le premier axe oppose les individus I4, I1, I7 et I5 d'une part aux individus I9, I10, I14 et I6 d'autre part. Les sujets du premier groupe obtiennent des scores généralement plus élevés que ceux du 2^e groupe, particulièrement sur les variables CUB, PUZ et CAL.

Le deuxième axe oppose les individus I8, I7 et I4 d'une part aux individus I1 et I11 d'autre part. On peut noter que l'individu I1 explique à lui seul plus du tiers de la variance de cet axe.

Chapitre 3 : Analyse Factorielle des correspondances (AFC)

1) Introduction

L'analyse factorielle des correspondances (AFC), ou analyse des correspondances simples, est une méthode exploratoire d'analyse des tableaux de contingence.

Soient deux variables nominales X et Y , comportant respectivement p et q modalités. On a observé les valeurs de ces variables sur une population et on dispose d'un tableau de contingence à p lignes et q colonnes donnant les effectifs conjoint c'est-à-dire les effectifs observés pour chaque combinaison d'une modalité i de X et d'une modalité j de Y .

Les valeurs de ce tableau seront notées n_{ij} , l'effectif total sera noté N .

L'ACP vise à analyser ce tableau en apportant des réponses à des questions telles que :

- Y a-t-il des lignes du tableau (modalités de X) qui se "ressemblent", c'est-à-dire telles que les distributions des modalités de Y soient analogues ?

- Y a-t-il des lignes du tableau (modalités de X) qui s'opposent, c'est-à-dire telles que les distributions des modalités de Y soient très différentes ?

- Mêmes questions pour les colonnes du tableau.

- Y a-t-il des associations modalité de X - modalité de Y qui s'attirent (effectif conjoint particulièrement élevé) ou qui se repoussent (effectif conjoint particulièrement faible) ?

La méthode se fixe également comme but de construire des représentations graphiques mettant en évidence ces propriétés des données.

L'ACP a permis de projeter sur un plan un résumé pertinent d'un tableau de données quantitatives.

L'AFC simple nous permettra de projeter sur un plan les structures d'un tableau de contingence (contient des fréquences d'association entre les modalités de deux variables qualitatives).

Tableau de contingence = Croisement de deux variables qualitatives X et Y

		Y					
		1	...	j	...	p	
X	1	k_{11}		k_{1j}		k_{1p}	$k_{i.}$
	:			:			
	i	k_{i1}	...	k_{ij}	...	k_{ip}	
	:			:			
	n	k_{n1}		k_{nj}		k_{np}	
		$k_{.j}$					k

Tableau des effectifs k_{ij}

On teste l'indépendance entre deux variables qualitatives par :

Le test du khi-deux d'indépendance

Test :

H0 : Les variables X et Y sont indépendantes

H1 : Les variables X et Y sont liées entre elles

Statistique utilisée :

k_{ij} = Effectif observé

$\frac{k_{i.} k_{.j}}{k}$ = Effectif attendu sous l'hypothèse d'indépendance

$\frac{k_{ij} - \frac{k_{i.} k_{.j}}{k}}{\sqrt{\frac{k_{i.} k_{.j}}{k}}}$ = Résidu standardisé (moyenne 0, écart-type 1)

$$\chi^2 = \sum_{i=1}^n \sum_{j=1}^p \frac{(k_{ij} - \frac{k_{i.} k_{.j}}{k})^2}{\frac{k_{i.} k_{.j}}{k}}$$

Décision :

On rejette H0 au risque α de se tromper si $\chi^2 \geq \chi^2_{1-\alpha, 2[(n-1)(p-1)]}$

Prenons l'exemple suivant qui croise deux variables qualitatives, la série en BAC et la destination après BAC :

Destination				
Séries	Univ	C.P	Autres	Total
A	13	2	5	20
BD	20	2	8	30
CE	10	5	5	20
Tech	7	1	22	30
Total	50	10	40	100

Nous avons 2 variables qualitatives dont le croisement des modalités donne le tableau de fréquence. Nous travaillons ici sur des effectifs. On constate par exemple que la moitié des lycéens vont à l'université

Les destinations choisies sont-elles indépendantes de la filière suivie au lycée.

- ➔ 50 lycéens se trouvent à l'université. Cela correspond à la moitié de l'effectif total.
- ➔ 30 étudiants sont issus des filières techniques.
- ➔ S'il y a indépendance entre les deux variables, nous devrions retrouver dans les universités 15 étudiants issus de filières techniques.
- ➔ Hors, nous n'en trouvons que 7.

Nous supposons qu'on s'écarte ici de la situation d'indépendance.

Résultats :

	Valeur singulière	Inertie	Khi- deux	Sig.	Proporti on d'inertie		Valeur singulière de confiance	
					Pris en compte	Cumulé	Ecart-type	Corrélation
Dimensi on								2
1	.447	.200			.802	.802	.091	.085
2	.222	.049			.198	1.000	.120	
Total		.249	24.917	.000	1.000	1.000		

a 6 degrés de liberté

Conclusion :

Donc il y a une dépendance entre la série en Bac et la destination après Bac :

$$(\chi^2 < \chi^2_{1-\alpha, 2[(n-1)(p-1)]}).$$

2) Analyse factorielle des correspondances avec SPSS

Nous allons utiliser un tableau de données représentant la ventilation d'une population de 31 079 individus, selon deux caractères qualitatifs que l'on croise:

- La catégorie socioprofessionnelle (en lignes)
- Le mode d'hébergement en vacance (en colonnes)

Un tel tableau est appelé tableau de contingence.

■ Catégories socio-professionnelles (CSP)

AGRI: agriculteurs

SALAG: salariés agricoles

PATR: patrons

CADSUP: cadres supérieurs et prof libérales

CADMOY: cadres moyens

EMPL: employés

OUVR: ouvriers

SERV: personnels de service

AUTRE: autres actifs

NONACT: non actif

■ Modes d'hébergement (MH)

HOTEL: hôtel, pension de famille

LOCAT: maison louée chez habitant

MAISON: maison en propriété

PARENT: chez des parents

AMIS: chez des amis

CAMPING: tente, caravane

VVF: villages de vacances

DIVERS: autres modes

	Mode d'hébergement							
(CSP)	HOTEL	LACAT	MAISON	PARENT	AMIS	CAMPING	VVF	DIVERS
AGRI	160	28	0	321	36	141	45	65
SALAG	35	34	1	178	8	0	4	0
PATR	700	354	229	959	185	292	119	140
CADSUP	961	471	633	1580	305	360	162	148
CADMOY	572	537	279	1689	206	748	155	112
EMPL	441	404	166	1079	178	434	178	92
OUVR	783	1114	387	4052	497	1464	525	387
SERV	65	43	21	294	79	57	18	6
AUTRE	77	60	189	839	53	124	28	53
NONACT	741	332	327	1789	311	236	102	102

On saisie les données sous SPSS, on obtient :


tpAFC.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

4 :

	csp	mh	effectif	var	var	var
1	1	1	160			
2	1	2	28			
3	1	3	0			
4	1	4	321			
5	1	5	36			
6	1	6	141			
7	1	7	45			
8	1	8	65			
9	2	1	35			
10	2	2	34			
11	2	3	1			
12	2	4	178			
13	2	5	8			
14	2	6	0			
15	2	7	4			
16	2	8	0			
17	3	1	700			
18	3	2	354			
19	3	3	229			
20	3	4	959			
21	3	5	185			
22	3	6	292			
23	3	7	119			
24	3	8	140			

Avant de faire l'analyse, on clique sur données, pour pondérer les observations :



tpAFC.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

4 :

	csp	mh	effectif	var	var	var	var	var	var	var
1	1	1	160							
2										
3										
4										
5										
6										
7										
8										
9										
10										
11										
12										
13										
14	2	6	0							
15	2	7	4							
16	2	8	0							
17	3	1	700							
18	3	2	354							
19	3	3	229							
20	3	4	959							
21	3	5	185							
22	3	6	292							
23	3	7	119							
24	3	8	140							

Pondérer les observations

csp

mh

☐ Ne pas pondérer les observations

☒ Pondérer les observations par

Variable de pondération :

Etat courant : Ne pas pondérer

OK

Coller

Restaurer

Annuler

Aide

Puis on passe à l'analyse :

tpAFC.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

4 :

	csp	mh	effectif
1	1	1	160
2	1	2	28
3	1	3	0
4	1	4	321
5	1	5	36
6	1	6	141
7	1	7	45
8	1	8	65
9	2	1	35
10	2	2	34
11	2	3	1
12	2	4	178
13	2	5	8
14	2	6	0
15	2	7	4
16	2	8	0
17	3	1	700
18	3	2	354
19	3	3	229
20	3	4	959
21	3	5	185
22	3	6	292
23	3	7	119
24	3	8	140

Rapports
 Statistiques descriptives
 Tabuler
 Comparer les moyennes
 Modèle linéaire général
 Corrélation
 Régression
 Analyse log-linéaire
 Classification
 Factorisation
 Positionnement
 Tests non paramétriques
 Séries chronologiques
 Survie
 Réponses multiples

Analyse factorielle...
 Analyse des correspondances...
 Codage optimal...

tpAFC.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

4:

	csp	mh	effectif	var	var	var	var	var
1								
2								
3								
4								
5								
6								
7								
8								
9								
10								
11								
12								
13								
14								
15								
16								
17	3	1	700					
18	3	2	354					
19	3	3	229					
20	3	4	959					
21	3	5	185					
22	3	6	292					
23	3	7	119					

Analyse des correspondances

effectif


Ligne :
csp(? ?)
Définir intervalle...

Colonne :
mh(? ?)
Définir intervalle...


OK
Coller
Restaurer
Annuler
Aide

Modèle... Statistiques... Graphiques...


Puis on définit l'intervalle de chaque variable qualitative :




Puis on clique sur Modèle :



Puis on clique sur Statistiques :



Puis on clique sur Diagrammes :



Après, on met OK et on obtient les résultats de l'analyse :

Tableau des correspondances

	MH	LOCAT	MAISON	PARENT	AMIS	CAMPING	VVF	DIVERS	Marge
CSP	HOTEL								
AGRI	160	28	0	321	36	141	45	65	796
SALAG	35	34	1	178	8	0	4	0	260
PATR	700	354	229	959	185	292	119	140	2978
CADSUP	961	471	633	1580	305	360	162	148	4620
CADMOY	572	537	279	1689	206	748	155	112	4298
EMPL	441	404	166	1079	178	434	178	92	2972
OUVR	783	1114	387	4052	497	1464	525	387	9209
SERV	65	43	21	294	79	57	18	6	583
AUTRE	77	60	189	839	53	124	28	53	1423
NONACT	741	332	327	1789	311	236	102	102	3940
Marge	4535	3377	2232	12780	1858	3856	1336	1105	31079

Profils lignes

	MH								
CSP	HOTEL	LOCAT	MAISON	PARENT	AMIS	CAMPING	VVF	DIVERS	Marge
AGRI	,201	,035	,000	,403	,045	,177	,057	,082	1,000
SALAG	,135	,131	,004	,685	,031	,000	,015	,000	1,000
PATR	,235	,119	,077	,322	,062	,098	,040	,047	1,000
CADSUP	,208	,102	,137	,342	,066	,078	,035	,032	1,000
CADMOY	,133	,125	,065	,393	,048	,174	,036	,026	1,000
EMPL	,148	,136	,056	,363	,060	,146	,060	,031	1,000
OUVR	,085	,121	,042	,440	,054	,159	,057	,042	1,000
SERV	,111	,074	,036	,504	,136	,098	,031	,010	1,000
AUTRE	,054	,042	,133	,590	,037	,087	,020	,037	1,000
NONACT	,188	,084	,083	,454	,079	,060	,026	,026	1,000
Masse	,146	,109	,072	,411	,060	,124	,043	,036	

Profils colonnes

	MH								
CSP	HOTEL	LOCAT	MAISON	PARENT	AMIS	CAMPING	VVF	DIVERS	Masse
AGRI	,035	,008	,000	,025	,019	,037	,034	,059	,026
SALAG	,008	,010	,000	,014	,004	,000	,003	,000	,008
PATR	,154	,105	,103	,075	,100	,076	,089	,127	,096
CADSUP	,212	,139	,284	,124	,164	,093	,121	,134	,149
CADMOY	,126	,159	,125	,132	,111	,194	,116	,101	,138
EMPL	,097	,120	,074	,084	,096	,113	,133	,083	,096
OUVR	,173	,330	,173	,317	,267	,380	,393	,350	,296
SERV	,014	,013	,009	,023	,043	,015	,013	,005	,019
AUTRE	,017	,018	,085	,066	,029	,032	,021	,048	,046
NONACT	,163	,098	,147	,140	,167	,061	,076	,092	,127
Marge	1,000	1,000	1,000	1,000	1,000	1,000	1,000	1,000	

Résumé

	Valeurs propres	Khi-deux	Proportion d'inertie	
			inertie	Cumulé
1	,044		,530	,530
2	,020		,242	,772
3	,009		,105	,878
4	,005		,065	,943
5	,002		,028	,971
6	,002		,026	,997
7	,000		,003	1,000
Total	,084	2598,27 3	1,000	1,000

a 63 degrés de liberté

77,2% de l'inertie du tableau de données sera représenté sur le premier plan factoriel.

Le nombre de valeurs propres produites par la recherche des facteurs principaux est égal au minimum du nombre de lignes et du nombre de colonnes du tableau de contingence. Cependant, la première valeur propre est systématiquement égale à 1, et n'est pas mentionnée dans les résultats. Les autres valeurs propres sont des nombres positifs inférieurs à 1 et leur somme est égale à Φ^2 .

Caractéristiques des points lignes

	Masse	Score dans la dimension		Inertie	Contribution				
		1	2		Contribution absolue (1)	Contribution absolue (2)	De dimension à inertie de point		
CSP					1	2	1	2	Total
AGRI	,026	,303	,465	,006	,011	,039	,083	,132	,215
SALAG	,008	,079	-1,022	,004	,000	,061	,003	,335	,338
PATR	,096	-,457	,488	,008	,095	,160	,519	,401	,920
CADSUP	,149	-,710	,057	,017	,356	,003	,904	,004	,908
CADMOY	,138	,220	,158	,004	,032	,024	,328	,114	,442
EMPL	,096	,151	,345	,003	,010	,080	,176	,623	,799
OUVR	,296	,514	-,022	,017	,373	,001	,972	,001	,973
SERV	,019	,083	-,533	,003	,001	,037	,008	,223	,231
AUTRE	,046	-,019	-1,256	,012	,000	,507	,000	,863	,864
NONACT	,127	-,451	-,311	,009	,122	,086	,590	,189	,779
Total actif	1,000			,084	1,000	1,000			

a Normalisation principale symétrique


Caractéristiques des points colonnes

	Masse	Score dans la dimension		Inertie	Contribution				
		1	2		Contribution absolue (1)	Contribution absolue (2)	De dimension à inertie de point		
MH					1	2	1	2	Total
HOTEL	,146	-,718	,463	,022	,357	,220	,729	,205	,934
LOCAT	,109	,169	,366	,006	,015	,102	,116	,368	,484
MAISON	,072	-,889	-,348	,018	,269	,061	,655	,068	,723
PARENT	,411	,139	-,380	,011	,038	,417	,153	,778	,931
AMIS	,060	-,246	-,023	,004	,017	,000	,202	,001	,203
CAMPING	,124	,657	,373	,016	,254	,121	,724	,158	,881
VVF	,043	,465	,431	,004	,044	,056	,471	,274	,746
DIVERS	,036	,180	,295	,004	,005	,022	,066	,120	,186
Total actif	1,000			,084	1,000	1,000			

a Normalisation principale symétrique

88% de l'inertie du premier facteur est dû à 3 modalités (HOTEL, MAISON ET CAMPING).

Représentation graphique :



Proximité entre modes d'hébergement en vacances et catégories socio -professionnelles.

En terme de CSP:

- ➔ $E^+ = \{\text{cadres (35,6), non actif (12,2), patron (9,5)}\}$
- ➔ $E^- = \{\text{ouvrier (37,3)}\}$
- ➔ Ces 4 points expliquent 95% de l'inertie.

En terme de MH:

- ➔ $E+=\{\text{hotel (35,7), prop (26,9)}\}$
- ➔ $E-=\{\text{tente (25,4), village (4,4)}\}$

- ➔ Le premier axe oppose les ouvriers qui ont une forte fréquentation des modes d'hébergement, tente et village de vacances et une faible fréquentation de l'hôtel et maisons des prop au CSP, non actif et patron qui ont au contraire une forte fréquentation des tentes et village.
- ➔ Une représentation graphique est plus vivante qu'un tableau.
- ➔ La proximité entre deux points catégories socio -professionnelles signifiera une similitude des profils d'hébergement (profils lignes). Il est ainsi pour les patrons et les professionnels libéraux, par exemple.
- ➔ La proximité entre deux points mode d'hébergement exprimera une similitude des profils socio-professionnels (profils colonnes). C'est ce que l'on constate pour par exemple: village de vacances et tentes et caravanes.

Chapitre 4 : Analyse des Correspondances Multiples (ACM)

1) Introduction

L'analyse factorielle des correspondances, vue dans le chapitre précédent, s'applique à des situations où les individus statistiques sont décrits par deux variables nominales (qualitatives). Mais il est fréquent que l'on dispose d'individus décrits par plusieurs (deux ou plus) variables nominales ou ordinales. C'est notamment les cas lorsque nos données sont les résultats d'une enquête basée sur des questions fermées à choix multiples. Une extension de l'AFC à ces situations a donc été proposée. Elle est généralement appelée Analyse des Correspondances Multiples ou ACM.

Nous nous plaçons donc dans la situation où nous disposons de N individus statistiques, décrits par Q variables nominales ou ordinales $X_1, X_2, \dots, X_Q$. l'ACM vise à mettre en évidence :

- Les relations entre les modalités des différentes variables ;
- Eventuellement, les relations entre individus statistiques ;
- Les relations entre les variables, telles qu'elles apparaissent à partir des relations entre modalités.

On note Q l'ensemble des variables (appelées « questions »). On désigne par K_q l'ensemble des modalités de la variable X_q et K l'ensemble de toutes les modalités de réponses.

- L'ACP permet de traiter des tableaux de données contenant des variables quantitatives
- L'AFC permet de traiter des tableaux de contingence (croisement de deux variables qualitatives)
- Dans la réalité, nous trouvons souvent des tableaux contenant à la fois des données quantitatives et des données qualitatives.

Par exemple:

Numéro Parcelle	Culture	Surface	Durée Précédent	Année
1	Blé	5,3	2	1987
2	Blé	8,2	1	1996

3	Riz	2	3	1988
4	Orge	1,5	1	1988
5	Riz	3,4	2	1988

L'AFC ne peut traiter que des tableaux de nombres. L'opération de codage va permettre de transformer les données pour rendre le traitement par l'AFC possible.

Données brutes

Parcelle	Culture	Surface	Précédent	Année
1	Blé	5,3	2	1987
2	Blé	8,2	1	1996
3	Riz	2	3	1988
4	Orge	1,5	1	1988
5	Riz	3,4	2	1988

Données codées

Parcelle	Culture	Surface	Précédent	Année
1	1	2	2	1
2	1	3	1	3
3	2	1	3	2
4	3	1	1	2
5	2	2	2	2

Tableau disjonctif complet

- Transformation des modalités du tableau codé en variable disjonctives

	Culture			Surface			Précéd.			Année		
	Blé	Riz	Orge	Faible	Moyen	Élevé	1	2	3	87	88	96
1	1	0	0	0	1	0	0	1	0	1	0	0
2	1	0	0	0	0	1	1	0	0	0	0	1
3	0	1	0	1	0	0	0	0	1	0	1	0
4	0	0	1	1	0	0	1	0	0	0	1	0
5	0	1	0	0	1	0	0	1	0	0	1	0

Nommer les modalités

- Chaque modalité disjonctive va recevoir un nom

	Cu1	Cu2	Cu3	Surf1	Surf2	Surf3	Pr1	Pr2	Pr3	A1	A2	A3
1	1	0	0	0	1	0	0	1	0	1	0	0
2	1	0	0	0	0	1	1	0	0	0	0	1
3	0	1	0	1	0	0	0	0	1	0	1	0
4	0	0	1	1	0	0	1	0	0	0	1	0
5	0	1	0	0	1	0	0	1	0	0	1	0

- Le nom des modalités doit être choisi afin de rester lisible une fois projeté sur le plan factoriel

Un Exemple de questionnaire

- Un questionnaire est formé d'un ensemble Q de questions dont chacune, admet un ensemble J_q de modalités de réponses;

On note:

$$J = \bigcup \{J_q/q \text{ appartient à } Q\}$$

Exemple: $Q = \{q1, q2, q3\}$

q1: fumez-vous: (F1 :faible); (F2: moyen); (F3: fort)?

q2: possédez-vous une automobile: (A1: oui);(A2: non)?

q3: adhérez-vous à un parti ou un mouvement politique: (P1: oui); (P2: non)?

- Dans le cas de l'exemple, on donc:

$$J_{q1} = \{F1, F2, F3\}; J_{q2} = \{A1, A2\}; J_{q3} = \{P1, P2\} \quad J = \{F1, F2, F3, A1, A2, P1, P2\}$$

- On notera l'usage de chiffres dans les sigles; afin de distinguer, e.g. le *oui* à la question 2, du *oui* à la question 3
- Le questionnaire est soumis à un ensemble I de n sujets (Card I = n). Les réponses fournies peuvent être rassemblées en un tableau (I x Q), à n lignes et Q colonnes, avec à la croisée de la ligne i (individu i) et de la colonne q, l'indication de l'élément de l'ensemble J_q fournit par le sujet i à la question q : c'est ce qu'on appelle *le tableau des données brutes*.
- A titre d'exercice, on considère ici le tableau brut des réponses de dix sujet au questionnaire ci-dessus.
- R_{iq}: réponse du ième individu à la question q. Ce tableau a l'avantage d'être le tableau contenant toute l'information disponible, le plus réduit, de taille minimale.

	q1	q2	q3
i1	F1	A1	P2
i2	F3	A1	P1
i3	F1	A2	P2

i4	F2	A2	P2
i5	F3	A2	P1
i6	F2	A1	P2
i7	F1	A1	P2
i8	F1	A2	P1
i9	F3	A1	P2
i10	F2	A2	P2

Exemple de tableau brut: $R_{I \times Q}$

- En vue de l'analyse des correspondance, il est d'usage de constituer un tableau numérique KIJ, ne comportant que des zéros et des uns suivant le code:

$K(i,j)=1$ si l'individu i a adopté la modalité j; et $K(i,j)=0$ sinon.

- Si chaque sujet i fournit à chaque question q une modalité de réponse et une seule, (i.e. un élément j de J_q ; où on aura pu prévoir la modalité « absence de réponse »), il y a dans chaque ligne i, un chiffre 1 et un seul par groupe J_q de colonnes. On dit alors que le tableau en (0,1) est un *tableau sous forme disjonctive complète*.

Kij	F1	F2	F3	A1	A2	P1	P2	marge
i1	1	0	0	1	0	0	1	3
i2	0	0	1	1	0	1	0	3
i3	1	0	0	0	1	0	1	3
i4	0	1	0	0	1	0	1	3
i5	0	0	1	0	1	1	0	3
i6	0	1	0	1	0	0	1	3
i7	1	0	0	1	0	0	1	3
i8	1	0	0	0	1	1	0	3
i9	0	0	1	1	0	0	1	3
i10	0	1	0	0	1	0	1	3
marge	4	3	3	5	5	3	7	30

Tableau de description logique: $Z_{I \times J}$

- On appelle tableau de Burt (associé aux réponses fournies par l'ensemble I de sujets à l'ensemble Q de questions) le tableau $K'JJ'$ donnant à l'intersection de la ligne j et de la colonne j' le nombre $k'(j,j')$ des sujets i de I ayant adopté simultanément les modalités j et j' (i.e. des i tels que $k(i,j) = k(i,j')=1$).
- Croise les modalités avec les modalités, il est diagonale, car il est disjonctif, la somme des diagonaux = 10, car il est complet.
- C'est un tableau de contingence multiple

$$B = Z'Z$$

	F1	F2	F3	A1	A2	P1	P2
--	----	----	----	----	----	----	----

F1	4	0	0	2	2	1	3
F2	0	3	0	1	2	0	3
F3	0	0	3	2	1	2	1
A1	2	1	2	5	0	1	4
A2	2	2	1	0	5	2	3
P1	1	0	2	1	2	3	0
P2	3	3	1	4	3	0	7

Tableau de Burt: $B_{j \times j}$

Application sous SPSS

Selon leur origine, les données sur lesquelles nous nous proposons de faire une ACM peuvent se présenter sous différentes formes.

Imaginons, par exemple, une mini-enquête dans laquelle nous avons posé trois questions à 10 sujets : le sexe (F ou H), le niveau de revenus (M : modeste, E : élevé) et leur préférence sur un sujet donné (3 modalités : A, B ou C). Les données peuvent se présenter sous l'une des formes décrites ci-dessous.

Tableau des données Brutes

	1-Sexe	2-Revenu	3-Preference
s1	F	M	A
s2	F	M	A
s3	F	E	B
s4	F	E	C
s5	F	E	C
s6	H	E	C
s7	H	E	B
s8	H	M	B
s9	H	M	B
s10	H	M	A

Tableau disjonctif complet

Le tableau disjonctif complet ou TDC comporte une colonne pour chaque modalité des variables étudiées et une ligne pour chaque individu statistique. Les cellules du tableau contiennent 1 ou 0 selon que l'individu considéré présente la modalité ou non.

	1- Sexe:F	2- Sexe:H	3- Rev:M	4- Rev:E	5- Pref:A	6- Pref:B	7- Pref:C
s1	1	0	1	0	1	0	0
s2	1	0	1	0	1	0	0
s3	1	0	0	1	0	1	0
s4	1	0	0	1	0	0	1
s5	1	0	0	1	0	0	1
s6	0	1	0	1	0	0	1
s7	0	1	0	1	0	1	0
s8	0	1	1	0	0	1	0


s9	0	1	1	0	0	1	0
s10	0	1	1	0	1	0	0

Tableau de Burt

L'ACM peut également être réalisée à partir d'une structuration particulière des données, appelée tableau de Burt (TdB). Ce dernier tableau comporte une ligne et une colonne pour chaque modalité des variables étudiées. Chaque cellule du tableau indique le nombre d'individus statistiques qui possèdent en même temps la modalité ligne et la modalité colonne correspondante. Le tableau de Burt apparaît ainsi comme une juxtaposition de tableaux de contingence des variables prises deux à deux.

	F	H	M	E	A	B	C
F	5	0	2	3	2	1	2
H	0	5	3	2	1	3	1
M	2	3	5	0	3	2	0
E	3	2	0	5	0	2	3
A	2	1	3	0	3	0	0
B	1	3	2	2	0	4	0
C	2	1	0	3	0	0	3

Quantifications



Bien que l'exemple ne comporte qu'un petit nombre d'observations, on remarque la proximité des modalités Préférence:B et Sexe:H, de même que l'opposition Préférence C, revenu E d'une part, Préférence A, Revenu M d'autre part selon le premier axe.

2) Analyse des correspondances multiples avec SPSS

2-1- Les données :

En 2003, l'INSEE a fait une enquête appelée "Participation culturelle et sportive" dont le but est de mieux cerner les différentes formes de participation à la vie culturelle et sportive. Cette enquête avait plusieurs intérêts en particulier :

- Observer l'interaction entre ces deux formes prépondérantes d'usage du temps libre,
- Mieux connaître les personnes pratiquant telle ou telle activité
- Mieux comprendre les raisons de la non pratique

De cette enquête, nous avons extrait un échantillon de 50 individus et leurs réponses à 6 questions qui ont permis de définir 6 variables qualitatives. Nous n'allons pas utiliser cet échantillon ridicule pour essayer de rendre compte des réponses à ces préoccupations. Nous allons simplement essayer de montrer comment on fait en pratique pour analyser un tel fichier.

Les variables de l'analyse sont : VELO, PETA, TELE, LIVR, SEXE, DIPL.

1) VELO : Pratiquez vous la natation, le vélo ou la randonnée ?

- VELO1 : Jamais
- VELO2 : Moins d'une fois par semaine
- VELO3 : Une fois par semaine ou plus

2) PETA : Pratiquez-vous la Pétanque, la Chasse ou la Pêche ?

- PETA1 : Jamais
- PETA2 : Moins d'une fois par mois
- PETA3 : Une fois par mois ou plus

3) TELE : Regardez-vous la télé ?

- TELE1 : matin
- TELE2 : après midi
- TELE3 : soir

4) LIVR : Combien de livres avez-vous lu au cours des 12 derniers mois ?

- LIVR1 : aucun
- LIVR2 : 1 à 9 livres
- LIVR3 : 10 à 24 livres
- LIVR4 : 25 ou plus

5) SEXE : Etes vous un Homme ou une Femme?

- SEXE1 : Homme
- SEXE2 : Femme

6) DIPL : Quel est le niveau de votre plus haut diplôme ?

- DIPL1 : aucun ou CEP
- DIPL2 : inférieur au Bac
- DIPL3 : Bac
- DIPL4 : supérieur au Bac

Les réponses des 50 individus sont données dans le tableau ci dessous :

IND	VELO	PETA	TELE	LECT	SEXE	DIPL
ind 1	1	1	1	2	2	1
ind 2	1	1	1	1	2	2
ind 3	1	1	1	2	2	2
ind 4	2	2	2	2	1	2
ind 5	1	1	1	1	2	4
ind 6	1	1	3	1	1	2
ind 7	3	1	1	4	1	2
ind 8	1	1	3	2	2	1
ind 9	3	3	2	2	1	2
ind 10	3	3	1	4	2	4
ind 11	2	1	1	1	1	3
ind 12	1	1	2	4	2	2
ind 13	2	1	1	3	1	3
ind 14	2	2	1	4	1	2
ind 15	3	2	2	3	1	4
ind 16	1	1	1	4	2	2
ind 17	2	1	1	2	1	2
ind 18	3	2	2	2	1	3
ind 19	2	3	1	2	2	2
ind 20	1	1	1	3	1	1
ind 21	1	3	1	2	1	1
ind 22	2	3	1	4	1	3
ind 23	1	1	3	1	2	4
ind 24	1	1	1	1	1	1
ind 25	2	2	1	3	2	4
ind 26	2	1	2	3	1	2
ind 27	1	1	3	2	2	2
ind 28	2	1	2	4	2	3
ind 29	1	1	2	2	2	2
ind 30	3	1	3	2	2	1
ind 31	1	1	3	2	1	1
ind 32	1	1	1	1	1	1
ind 33	1	1	2	2	1	2
ind 34	3	1	1	3	2	2
ind 35	3	3	1	1	1	1
ind 36	1	1	1	3	2	1
ind 37	3	1	1	3	2	4
ind 38	2	2	1	4	2	2
ind 39	3	3	1	2	1	4
ind 40	3	1	2	1	2	4
ind 41	1	1	1	2	1	1
ind 42	1	1	1	3	1	1

ind 43	2	3	1	4	1	4
ind 44	2	2	2	1	2	1
ind 45	3	1	1	3	1	2
ind 46	1	1	3	3	2	2
ind 47	3	1	1	3	2	3
ind 48	1	1	1	4	2	2
ind 49	1	1	2	2	2	1
ind 50	2	2	1	2	1	2

2-2- Le tableau disjonctif complet et le tableau de Burt

Avant toute calcul, il faut être conscient du fait qu'il n'est pas question d'appliquer brutalement une méthode d'analyse des données à ce tableau : les nombres dans le tableau représentent simplement des codages des réponses individuelles, on n'a pas le droit de les additionner ou de les multiplier.

On utilise deux astuces pour transformer ce tableau de données en tableau "analysable" ;

La première astuce pour analyser un tel tableau consiste à définir pour chaque variable autant de réponses possibles qu'il y a de modalités. Prenons la variable VELO par exemple. Elle admet 3 modalités de réponses. On peut la représenter par un vecteur 3 questions -modalités différentes (VELO1, VELO2, VELO3). Un individu qui aurait :

La réponse 1 à la variable VELO aura les réponses

VELO 1	VELO 2	VELO 3
1	0	0

La réponse 2 à la variable VELO aura les réponses

VELO 1	VELO 2	VELO 3
0	1	0

la réponse 3 à la variable VELO aura les réponses

VELO 1	VELO 2	VELO 3
0	0	1

En reproduisant ce procédé pour les 6 variables, on obtient ce que l'on appelle un **tableau disjonctif complet** (l'ensemble des valeurs des variables -modalités d'une même variable comporte une fois (complet) la valeur 1 et une seule (disjonctif).

	VELO			PETA			TELE			LECT				SEXE		DIPL			
ind.	VELO1	VELO2	VELO3	PETA1	PETA2	PETA3	TELE1	TELE2	TELE3	LECT1	LECT2	LECT3	LECT4	SEXE1	SEXE2	DIPL1	DIPL2	DIPL3	DIPL4
ind1	1	0	0	1	0	0	1	0	0	0	1	0	0	0	1	1	0	0	0
ind2	1	0	0	1	0	0	1	0	0	1	0	0	0	0	1	0	1	0	0
ind3	1	0	0	1	0	0	1	0	0	0	1	0	0	0	1	0	1	0	0
ind4	0	1	0	0	1	0	0	1	0	0	1	0	0	1	0	0	1	0	0
ind5	1	0	0	1	0	0	1	0	0	1	0	0	0	0	1	0	0	0	1
ind6	1	0	0	1	0	0	0	0	1	1	0	0	0	1	0	0	1	0	0
ind7	0	0	1	1	0	0	1	0	0	0	0	0	1	1	0	0	1	0	0
ind8	1	0	0	1	0	0	0	0	1	0	1	0	0	0	1	1	0	0	0
ind9	0	0	1	0	0	1	0	1	0	0	1	0	0	1	0	0	1	0	0
ind10	0	0	1	0	0	1	1	0	0	0	0	0	1	0	1	0	0	0	1
ind11	0	1	0	1	0	0	1	0	0	1	0	0	0	1	0	0	0	1	0
ind12	1	0	0	1	0	0	0	1	0	0	0	0	1	0	1	0	1	0	0
ind13	0	1	0	1	0	0	1	0	0	0	0	1	0	1	0	0	0	1	0
ind14	0	1	0	0	1	0	1	0	0	0	0	0	1	1	0	0	1	0	0
ind15	0	0	1	0	1	0	0	1	0	0	0	1	0	1	0	0	0	0	1
ind16	1	0	0	1	0	0	1	0	0	0	0	0	1	0	1	0	1	0	0
ind17	0	1	0	1	0	0	1	0	0	0	1	0	0	1	0	0	1	0	0
ind18	0	0	1	0	1	0	0	1	0	0	1	0	0	1	0	0	0	1	0
ind19	0	1	0	0	0	1	1	0	0	0	1	0	0	0	1	0	1	0	0
ind20	1	0	0	1	0	0	1	0	0	0	0	1	0	1	0	1	0	0	0
ind21	1	0	0	0	0	1	1	0	0	0	1	0	0	1	0	1	0	0	0
ind22	0	1	0	0	0	1	1	0	0	0	0	0	1	1	0	0	0	1	0
ind23	1	0	0	1	0	0	0	0	1	1	0	0	0	0	1	0	0	0	1
ind24	1	0	0	1	0	0	1	0	0	1	0	0	0	1	0	1	0	0	0
ind25	0	1	0	0	1	0	1	0	0	0	0	1	0	0	1	0	0	0	1
ind26	0	1	0	1	0	0	0	1	0	0	0	1	0	1	0	0	1	0	0
ind27	1	0	0	1	0	0	0	0	1	0	1	0	0	0	1	0	1	0	0
ind28	0	1	0	1	0	0	0	1	0	0	0	0	1	0	1	0	0	1	0
ind29	1	0	0	1	0	0	0	1	0	0	1	0	0	0	1	0	1	0	0
ind30	0	0	1	1	0	0	0	0	1	0	1	0	0	0	1	1	0	0	0
ind31	1	0	0	1	0	0	0	0	1	0	1	0	0	1	0	1	0	0	0
ind32	1	0	0	1	0	0	1	0	0	1	0	0	0	1	0	1	0	0	0
ind33	1	0	0	1	0	0	0	1	0	0	1	0	0	1	0	0	1	0	0
ind34	0	0	1	1	0	0	1	0	0	0	0	1	0	0	1	0	1	0	0
ind35	0	0	1	0	0	1	1	0	0	1	0	0	0	1	0	1	0	0	0
ind36	1	0	0	1	0	0	1	0	0	0	0	1	0	0	1	1	0	0	0
ind37	0	0	1	1	0	0	1	0	0	0	0	1	0	0	1	0	0	0	1
ind38	0	1	0	0	1	0	1	0	0	0	0	0	1	0	1	0	1	0	0
ind39	0	0	1	0	0	1	1	0	0	0	1	0	0	1	0	0	0	0	1
ind40	0	0	1	1	0	0	0	1	0	1	0	0	0	0	1	0	0	0	1
ind41	1	0	0	1	0	0	1	0	0	0	1	0	0	1	0	1	0	0	0
ind42	1	0	0	1	0	0	1	0	0	0	0	1	0	1	0	1	0	0	0
ind43	0	1	0	0	0	1	1	0	0	0	0	0	1	1	0	0	0	0	1
ind44	0	1	0	0	1	0	0	1	0	1	0	0	0	0	1	1	0	0	0
ind45	0	0	1	1	0	0	1	0	0	0	0	1	0	1	0	0	1	0	0
ind46	1	0	0	1	0	0	0	0	1	0	0	1	0	0	1	0	1	0	0
ind47	0	0	1	1	0	0	1	0	0	0	0	1	0	0	1	0	0	1	0
ind48	1	0	0	1	0	0	1	0	0	0	0	0	1	0	1	0	1	0	0
ind49	1	0	0	1	0	0	0	1	0	0	1	0	0	0	1	1	0	0	0
ind50	0	1	0	0	1	0	1	0	0	0	1	0	0	1	0	0	1	0	0
TOTAL	23	14	13	34	8	8	31	12	7	10	18	12	10	25	25	14	21	6	9

La somme des éléments d'une colonne représente le nombre d'individus ayant choisi la modalité représentée par cette colonne : ainsi dans l'échantillon, 23 personnes ne pratiquent jamais le vélo ou la randonnée, 10 personnes lisent plus de 25 livres dans l'année.

La somme des éléments d'une ligne est constante et est égale au nombre de variables étudiées.

La technique de **l'analyse des correspondances multiples** consiste à appliquer les techniques de l'analyse des correspondances des leçons précédentes à un tel fichier.

La seconde astuce consiste à calculer pour chaque couple de variables, le tableau de leur croisement. On construit un tableau qui regroupe tous les croisements possibles :

	VELO1	VELO2	VELO3	PETA1	PETA2	PETA3	TELE1	TELE2	TELE3	LECT1	LECT2	LECT3	LECT4	SEXE1	SEXE2	DIPL1	DIPL2	DIPL3	DIPL4	total
VELO1	23	0	0	22	0	1	13	4	8	6	10	4	3	9	14	11	10	0	2	138
VELO2	0	14	0	5	8	3	10	4	0	2	4	3	5	9	5	1	7	4	2	84
VELO3	0	0	13	7	2	4	8	4	1	2	4	5	2	7	8	2	4	2	5	78
PETA1	22	5	7	34	0	0	20	7	7	8	11	10	5	14	20	11	15	4	4	204
PETA2	0	8	2	0	8	0	4	4	0	1	3	2	2	5	3	1	4	1	2	48
PETA3	1	3	4	0	0	8	7	1	0	1	4	0	3	8	2	2	2	1	3	48
TELE1	13	10	8	20	4	7	31	0	0	6	8	9	8	17	14	9	12	4	8	186
TELE2	4	4	4	7	4	1	0	12	0	2	6	2	2	8	8	2	8	2	2	72
TELE3	8	0	1	7	0	0	0	0	7	2	4	1	0	2	5	3	3	0	1	42
LECT1	6	2	2	8	1	1	8	2	2	10	0	0	0	5	5	4	2	1	3	60
LECT2	10	4	4	11	3	4	8	8	4	0	18	0	0	10	8	7	9	1	1	108
LECT3	4	3	5	10	2	0	9	2	1	0	0	12	0	8	8	3	4	2	3	72
LECT4	3	5	2	5	2	3	8	2	0	0	0	0	10	4	6	0	8	2	2	60
SEXE1	9	9	7	14	5	8	17	8	2	5	10	8	4	25	0	8	10	4	3	150
SEXE2	14	5	6	20	3	2	14	8	5	5	8	8	8	0	25	6	11	2	6	150
DIPL1	11	1	2	11	1	2	9	2	3	4	7	3	0	8	6	14	0	0	0	84
DIPL2	10	7	4	15	4	2	12	8	3	2	9	4	8	10	11	0	21	0	0	126
DIPL3	0	4	2	4	1	1	4	2	0	1	1	2	2	4	2	0	0	8	0	36
DIPL4	2	2	5	4	2	3	6	2	1	3	1	3	2	3	6	0	0	0	9	54
total	138	84	78	204	48	48	186	72	42	60	108	72	60	150	150	84	126	36	54	1800

Le tableau de Burt que l'on obtient ici n'est pas un tableau de contingence mais plutôt une juxtaposition de tableaux croisant les variables entre elles. S'il y a 6 questions dans le fichier à analyser, le tableau de Burt est la juxtaposition de $6 \times 6 = 36$ tableaux de contingence. Chaque individu y est compté 36 fois et la somme des nombres inscrits dans ce tableau vaut donc $36 \times 50 = 1800$.

Ce tableau est clairement symétrique par rapport à sa diagonale, les tableaux de la diagonale en grisé donnent les effectifs de chacune des modalités.

Il se trouve qu'en appliquant les techniques de l'analyse des correspondances sur ce tableau, on obtient pratiquement les mêmes résultats que ceux de l'analyse du tableau disjonctif complet. Aussi l'analyse des correspondances multiples désigne l'analyse du **tableau disjonctif complet** aussi bien que celle du **tableau de Burt**.

Pour illustrer l'équivalence de ces deux méthodes, nous allons les appliquer à l'exemple du sport et de la culture, puis à un second exemple qui traitera des pratiques de tri.

2-3- Les pratiques culturelles et sportives

Dans cet exemple, les trois premières variables représentent des comportements des individus. Les deux dernières variables représentent des caractéristiques socio - démographiques. Nous allons essayer d'analyser les comportements en traitant les trois premières variables comme actives, et les deux dernières comme illustratives.

a) L'analyse du tableau disjonctif complet

Comme nous l'avons dit, nous commençons par traiter ce fichier par la méthode du tableau disjonctif complet, et nous n'aurons comme variables actives que les trois premières. En bref, le tableau analysé est le suivant :

	VELO			PETA			TELE			LECT				
ind	VELO1	VELO2	VELO3	PETA1	PETA2	PETA3	TELE1	TELE2	TELE3	LECT1	LECT2	LECT3	LECT4	total
ind1	1	0	0	1	0	0	1	0	0	0	1	0	0	4
ind2	1	0	0	1	0	0	1	0	0	1	0	0	0	4
ind3	1	0	0	1	0	0	1	0	0	0	1	0	0	4
ind4	0	1	0	0	1	0	0	1	0	0	1	0	0	4
ind5	1	0	0	1	0	0	1	0	0	1	0	0	0	4
ind6	1	0	0	1	0	0	0	0	1	1	0	0	0	4
ind7	0	0	1	1	0	0	1	0	0	0	0	0	1	4
ind8	1	0	0	1	0	0	0	0	1	0	1	0	0	4
ind9	0	0	1	0	0	1	0	1	0	0	1	0	0	4
ind10	0	0	1	0	0	1	1	0	0	0	0	0	1	4
ind11	0	1	0	1	0	0	1	0	0	1	0	0	0	4
ind12	1	0	0	1	0	0	0	1	0	0	0	0	1	4
ind13	0	1	0	1	0	0	1	0	0	0	0	1	0	4
ind14	0	1	0	0	1	0	1	0	0	0	0	0	1	4
ind15	0	0	1	0	1	0	0	1	0	0	0	1	0	4
ind16	1	0	0	1	0	0	1	0	0	0	0	0	1	4
ind17	0	1	0	1	0	0	1	0	0	0	1	0	0	4
ind18	0	0	1	0	1	0	0	1	0	0	1	0	0	4
ind19	0	1	0	0	0	1	1	0	0	0	1	0	0	4
ind20	1	0	0	1	0	0	1	0	0	0	0	1	0	4
ind21	1	0	0	0	0	1	1	0	0	0	1	0	0	4
ind22	0	1	0	0	0	1	1	0	0	0	0	0	1	4
ind23	1	0	0	1	0	0	0	0	1	1	0	0	0	4
ind24	1	0	0	1	0	0	1	0	0	1	0	0	0	4
ind25	0	1	0	0	1	0	1	0	0	0	0	1	0	4
ind26	0	1	0	1	0	0	0	1	0	0	0	1	0	4
ind27	1	0	0	1	0	0	0	0	1	0	1	0	0	4
ind28	0	1	0	1	0	0	0	1	0	0	0	0	1	4
ind29	1	0	0	1	0	0	0	1	0	0	1	0	0	4
ind30	0	0	1	1	0	0	0	0	1	0	1	0	0	4
ind31	1	0	0	1	0	0	0	0	1	0	1	0	0	4
ind32	1	0	0	1	0	0	1	0	0	1	0	0	0	4
ind33	1	0	0	1	0	0	0	1	0	0	1	0	0	4
ind34	0	0	1	1	0	0	1	0	0	0	0	1	0	4
ind35	0	0	1	0	0	1	1	0	0	1	0	0	0	4
ind36	1	0	0	1	0	0	1	0	0	0	0	1	0	4
ind37	0	0	1	1	0	0	1	0	0	0	0	1	0	4
ind38	0	1	0	0	1	0	1	0	0	0	0	0	1	4
ind39	0	0	1	0	0	1	1	0	0	0	1	0	0	4
ind40	0	0	1	1	0	0	0	1	0	1	0	0	0	4
ind41	1	0	0	1	0	0	1	0	0	0	1	0	0	4
ind42	1	0	0	1	0	0	1	0	0	0	0	1	0	4
ind43	0	1	0	0	0	1	1	0	0	0	0	0	1	4
ind44	0	1	0	0	1	0	0	1	0	1	0	0	0	4
ind45	0	0	1	1	0	0	1	0	0	0	0	1	0	4
ind46	1	0	0	1	0	0	0	0	1	0	0	1	0	4
ind47	0	0	1	1	0	0	1	0	0	0	0	1	0	4
ind48	1	0	0	1	0	0	1	0	0	0	0	0	1	4
ind49	1	0	0	1	0	0	0	1	0	0	1	0	0	4
ind50	0	1	0	0	1	0	1	0	0	0	1	0	0	4
TOTAL	23	14	13	34	8	8	31	12	7	10	18	12	10	200

Avant de lancer le programme d'analyse des correspondances, commençons par calculer les distances entre chaque colonne et la marge ou plus précisément les distances entre les profils colonne et le profil marginal.

b) Étude des distances des profils colonnes à la marge

La marge du tableau est remarquable, puisque tous les nombres de la colonne "total" sont égaux ici à 4, plus généralement au nombre de variables étudiées. Ce qui fait que les poids des individus sont tous égaux à $1/n$ où n est le nombre d'individus du fichier (dans l'exemple étudié, n vaut 50). Prenons la première colonne : elle ne contient que des 1 et des 0. Soit 23 nombres 1 et 27 nombres 0. Quand je calcule le profil de cette colonne, il faut tout diviser par

23 et les nombres que l'on observe dans le profil colonne sont soit égaux à 1/23 soit égaux à 0.

La contribution d'un individu qui a 1/23 est de : $(1/23 - 1/50)^2 / 1/50 = 50*(1/23 - 1/50)^2$

La contribution d'un individu qui a 0 est de : $(0-1/50)^2 / 1/50 = 50*(1/50)^2 = 1/50$

On compte 23 individus du premier type et 27 individus du second type : la distance entre le profil de la première colonne et le profil marginal vaut donc :

$$d_1 = 23 * 50 * \left(\frac{50-23}{50 * 23} \right)^2 + 27 * \frac{1}{50} = \frac{(50-23)^2}{50 * 23} + \frac{27}{50}$$

Comme $50-23 = 27$, on voit que :

$$d_1 = \frac{27^2}{23 * 50} + \frac{27}{50} = \frac{27}{50} \left(\frac{27}{23} + 1 \right) = \frac{27}{50} * \frac{50}{23} = \frac{27}{23}$$

Nous avons détaillé à outrance ce calcul pour qu'on se rende compte qu'il n'y a là rien de mystérieux. Evidemment, on peut le refaire pour chacune des colonnes du tableau, mais ce que l'on obtiendra est évidemment :

Si le fichier compte n individus, une colonne contient n_1 valeurs 1 et $(n-n_1)$ valeurs 0, alors la distance entre le profil colonne et le profil marginal vaut $\frac{n-n_1}{n_1}$.

On peut donc d'un seul coup d'oeil voir quelles sont les colonnes qui s'écartent le plus du profil marginal, ce sont les colonnes pour lesquelles les rapports $\frac{n-n_1}{n_1}$ sont le plus élevé,

c'est à dire, quand on revient aux modalités représentées par chaque colonne, les colonnes qui correspondent aux modalités les plus rares.

Dans cette analyse, on voit que :

Plus une modalité est rare, plus la colonne qui la représente s'écarte du profil moyen.

c) Distance d'une variable au profil marginal

Nous avons vu dans la leçon sur les composantes principales que la distance du χ^2 du tableau est en fait la somme pondérée des distances des profils colonnes à la marge. C'est à dire, en reprenant les notations précédentes :

- f_{ij} : représente la fréquence de la case (i,j)
- f_i : représente la fréquence de la ligne i
- f_j : représente la fréquence de la colonne j

La distance de la colonne j à la marge vaut :

$$d_j = \sum_{i=1}^n \frac{1}{f_i} \left(\frac{f_{ij}}{f_j} - f_i \right)^2$$

Nous avons trouvé que dans le cas qui nous occupe, $d_j = \frac{n - n_j}{n_j}$ où n_j représente le nombre de 1 dans la colonne j.

Δ , la distance du χ^2 est la somme pondérée des d_j : $\Delta = \sum_{j=1}^J f_j d_j$

Voyons l'exemple et sa première colonne :

$$n_1 = 23, \text{ total} = 200, f_1 = 23/200, d_1 = 27/23 = (n - n_1)/n_1$$

Dans ce cas, la contribution de la première colonne à la distance totale du χ^2 vaut :

$$f_1 d_1 = (23/200) * (27/23) = 27/200.$$

Plus généralement,

- si le fichier compte Q questions, chaque individu sera donc compté Q fois dans le tableau disjonctif et le total des 1 sera égal à nQ
- si une colonne -modalité compte n_1 valeurs 1, son écart à la marge vaut $\frac{n - n_1}{n_1}$ et son poids vaut n_1/nQ .

Dans ces conditions, sa contribution à la distance du χ^2 vaut $\frac{n_1}{nQ} * \frac{n - n_1}{n_1} = \frac{n - n_1}{nQ}$

On retrouve le fait qu'une modalité a d'autant plus d'importance dans l'analyse qu'elle est rare (que n_1 est faible)

Intéressons nous maintenant à une variable comme la lecture qui a 4 modalités d'effectifs n_1, n_2, n_3, n_4 respectivement. On appelle Distance du χ^2 de la variable lecture la valeur δ_{lecture} égale à la somme des contributions de ses modalités :

$$\delta_{\text{lecture}} = \frac{n - n_1}{nQ} + \frac{n - n_2}{nQ} + \frac{n - n_3}{nQ} + \frac{n - n_4}{nQ} = \frac{4n - (n_1 + n_2 + n_3 + n_4)}{nQ}$$

Mais comme chaque individu prend une et une seule des modalités de la variable lecture, il est clair que $(n_1 + n_2 + n_3 + n_4)$ est égal au nombre d'individus n. On en déduit immédiatement que :

$$\delta_{\text{lecture}} = \frac{3n}{nQ} = \frac{3}{Q}$$

Plus généralement, il est immédiat d'en inférer que :

- si une variable a k modalités, sa contribution à la distance du χ^2 est de $\frac{k-1}{Q}$.
- Si le tableau disjonctif analysé a K modalités en tout Q questions, alors la distance totale du χ^2 vaut $\frac{K-Q}{Q}$.

Selon le premier résultat :

Une variable a une contribution à la distance du χ^2 d'autant plus importante qu'elle a de modalités.

On en tire l'idée que pour avoir une analyse des données qui ne donne pas systématiquement avantage à telle ou telle variable, il faudra s'arranger autant faire se peut pour que toutes les variables aient à peu près le même nombre de modalités et que les effectifs des différentes modalités ne soient "pas trop dissemblables".

Cette recommandation sert surtout quand il faudra rendre qualitatives des variables quantitatives comme par exemple le revenu des ménages, la taille des entreprises en nombre de salariés, le chiffre d'affaire des entreprises, Il faut résister à la tentation de faire des classes d'amplitude égales pour privilégier des classes d'effectifs égaux.

d) Étude des distances des individus à la marge

L'étude des distances des individus au centre n'est pas très riche en enseignements. Aussi nous allons à l'essentiel :

- si il y a Q questions,
- si un individu a répondu à la modalité a pour la question 1, b pour la question 2, ...etc
- si on note n_a le nombre d'individus qui ont choisi la modalité a pour la question 1, $n_b, \dots$

Alors la distance du profil d'un individu à la marge vaut $\frac{n}{Q} \left(\frac{1}{n_a} + \frac{1}{n_b} + \frac{1}{n_c} + \dots \right) - 1$

Un individu s'écarte d'autant plus de la marge qu'il prend des modalités rares. Si toutes les modalités ont même effectif, tous les individus sont à égale distance de la marge. Ils sont à la surface d'une "hypersphère".

Dans toutes les études de ce type, les valeurs propres seront toujours inférieures à l'unité.

e) Saisie des données sous SPSS

TP ACM enquete.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide



	Nom	Type	Largeur	Décimales	Etiquette	Valeurs	Manquant	Colonnes	Aligner	Mesure
1	individu	Numérique	8	0		Aucun	Aucun	8	Droite	Echelle
2	velo	Numérique	8	0		{1, VELO 1}...	Aucun	8	Droite	Echelle
3	peta	Numérique	8	0		{1, PETA 1}...	Aucun	8	Droite	Echelle
4	tele	Numérique	8	0		{1, TELE 1}...	Aucun	8	Droite	Echelle
5	livr	Numérique	8	0		{1, LIVR 1}...	Aucun	8	Droite	Echelle
6	sexe	Numérique	8	0		{1, SEXE 1}...	Aucun	8	Droite	Echelle
7	dipl	Numérique	8	0		{1, DIPL 1}...	Aucun	8	Droite	Echelle

TP ACM enquete.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide



3:

	individu	velo	peta	tele	livr	sexe	dipl
1	1	1	1	1	2	2	1
2	2	1	1	1	1	2	2
3	3	1	1	1	2	2	2
4	4	2	2	2	2	1	2
5	5	1	1	1	1	2	4
6	6	1	1	3	1	1	2
7	7	3	1	1	4	1	2
8	8	1	1	3	2	2	1
9	9	3	3	2	2	1	2
10	10	3	3	1	4	2	4
11	11	2	1	1	1	1	3
12	12	1	1	2	4	2	2
13	13	2	1	1	3	1	3
14	14	2	2	1	4	1	2
15	15	3	2	2	3	1	4
16	16	1	1	1	4	2	2
17	17	2	1	1	2	1	2
18	18	3	2	2	2	1	3
19	19	2	3	1	2	2	2
20	20	1	1	1	3	1	1
21	21	1	3	1	2	1	1
22	22	2	3	1	4	1	3
23	23	1	1	3	1	2	4
24	24	1	1	1	1	1	1

f) Analyse des correspondances multiples avec SPSS :

TP ACM enquete.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

Rapports
Statistiques descriptives
Tabuler
Comparer les moyennes
Modèle linéaire général
Corrélation
Régression
Analyse log-linéaire
Classification
Factorisation
Positionnement
Tests non paramétriques
Séries chronologiques
Survie
Réponses multiples

3:

	individu	velo	peta
1	1	1	1
2	2	1	1
3	3	1	1
4	4	2	2
5	5	1	1
6	6	1	1
7	7	3	1
8	8	1	1
9	9	3	3
10	10	3	3
11	11	2	1
12	12	1	1
13	13	2	1
14	14	2	2
15	15	3	2
16	16	1	1
17	17	2	1
18	18	3	2
19	19	2	3
20	20	1	1
21	21	1	3
22	22	2	3
23	23	1	1
24	24	1	1

sexe dipl var

2 1
2 2
2 2
1 2
2 1
1 2
2 4
1 3
2 2
1 3
1 2
2 3
1 4
2 2
1 2
1 3
2 2
1 1
1 1
1 3
2 4
1 1

Analyse factorielle...
Analyse des correspondances...
Codage optimal...

TP ACM enquete.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

Analyse d'homogénéité (HOMALS)

individu

velo

peta

tele

livr

sexe

dipl

►

Variables :

Définir intervalle...

OK

Coller

Restaurer

Annuler

Aide

Etiqueter les objets repérés sur le diagramme par leurs coordonnées principales :

►

Définir intervalle...

Options...

Dimensions de la solution 2

19	19	2	3	1	2	2	2
20	20	1	1	1	3	1	1
21	21	1	3	1	2	1	1
22	22	2	3	1	4	1	3
23	23	1	1	3	1	2	4
24	24	1	1	1	1	1	1

TP ACM enquete.sav - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

Analyse d'homogénéité (HOMALS)

Variables :

- velo(1 3)
- peta(1 3)
- tele(1 3)
- livr(1 4)
- sexe(1 2)
- dipl(1 4)

Définir intervalle...

Etiqueter les objets repérés sur le diagramme par leurs coordonnées principales :

- individu(1 10)

Définir intervalle...

Options...

Dimensions de la solution 2

19	19	2	3	1	2	2	2
20	20	1	1	1	3	1	1
21	21	1	3	1	2	1	1
22	22	2	3	1	4	1	3

Les différentes options de traitement peuvent être choisies en utilisant le bouton *<Options...>*. Ces options portent sur les résultats (*Display*), les graphiques (*Plot*), la sauvegarde des coordonnées factorielles des objets (*<Save object scores>*) et les critères de contrôle de l'algorithme (*Criteria*).



Les résultats demandés sont les distributions marginales obtenues par comptage, les valeurs propres, le pouvoir discriminant des variables actives, les coordonnées factorielles des modalités pour chaque variable, les coordonnées factorielles des objets.

Les graphiques demandés sont le graphique factoriel des modalités de variables actives, celui des objets et le diagramme du pouvoir discriminant des variables selon chacune des dimensions. A ces graphiques s'ajoutent autant de graphiques de densité des objets étiquetés par les modalités qu'il y a de variables illustratives.

La sauvegarde des coordonnées factorielles demandée s'effectue dans le fichier d'origine, mais peut être ultérieurement sauvegardé dans un fichier spécifique, comme suit, pour de nouvelles analyses (classification sur axes factoriels) :

TP ACM enquete.sav - Editeur de données SPSS


Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

1 : dipl 1


	individu	hom1_1	hom2_1	var	var	var
1	1	1,15	-,17			
2	2	,84	,09			
3	3	,76	-,65			
4	4	-1,17	-2,23			
5	5	,65	1,42			
6	6	1,29	-,32			
7	7	-,60	,23			
8	8	1,87	-,48			
9	9	-,76	-,17			
10	10	-1,10	2,19			
11	11	-,75	,07			
12	12	,18	-,99			
13	13	-1,00	,07			
14	14	-1,59	-1,32			
15	15	-1,25	,85			
16	16	,25	-,36			
17	17	-,37	-1,07			
18	18	-1,36	-,83			
19	19	-,68	-,44			
20	20	,71	,45			
21	21	,30	,22			
22	22	-1,92	,12			
23	23	1,37	1,12			
24	24	,96	,46			

Figure : sauvegarde des coordonnées factorielle des objets dans un fichier spécifique.

g) Nuage de point des modalités :



h) Nuage de point des individus :



i) Interprétation des résultats :

La superposition sur un même graphique des individus et des variables permet différentes interprétations : les interprétations faciles tout d'abord :

Proximités entre individus : deux individus sont proches si leur distance est faible, c'est à dire s'ils prennent "à peu près" les mêmes modalités des différentes variables.

Proximités entre modalités de deux variables différentes : deux points modalités de variables différentes sont proches si leur distance est faible : ce sont les mêmes individus qui prennent simultanément ces modalités.

D'autres interprétations peuvent être plus délicates :

Proximité entre individu et modalité un individu et un point modalité sont proches si l'individu prend cette modalité. Cette interprétation n'a de sens que si l'individu et la modalité sont bien représentés par l'axe (cosinus carré élevé).

proximité entre modalités différentes de la même variable : théoriquement les modalités de la même variable sont éloignées l'une de l'autre : elles s'excluent mutuellement. Sur le graphique elles peuvent être proches si les individus qui prennent l'une ou l'autre de ces modalités sont indistinguables pour les autres variables : ils forment un groupe et la distance impliquée par la distinction de ces deux modalités ne perturbe pas la cohésion du groupe.

L'interprétation des proximités entre modalités de variables différentes : on distingue 3 zones correspondant à :

- une pratique faible du Vélo et de la Pétanque,
- une pratique moyenne de ces deux activités
- et une pratique élevée de ces deux activités.
- La pratique de la Télé varie à l'inverse de ces deux activités : une pratique faible des 2 sports est associée à une pratique forte de la Télé etc...

La variable Lecture ne rentre pas dans cette analyse : on trouve d'un côté une faible pratique (LECT1 et LECT2) associée à une faible pratique du sport et une forte pratique de la Télé, et d'un autre une forte pratique de la lecture (LECT3 et LECT4) associée à une forte pratique du sport. On a ici une illustration de la proximité entre modalités de la même variable : le graphique montre que la distinction fine en 4 groupes de la Lecture ne semble pas pertinente.

Chapitre 5 : Analyse Factorielle Discriminante (AFD)

1. Introduction

- ✓ Le but de l'analyse discriminante est d'étudier les relations entre une variable qualitative et un ensemble de variables explicatives quantitatives. C'est une méthode utilisée notamment par les banques pour le scoring.
- ✓ Trois objectifs principaux peuvent être assignés à l'analyse discriminante:
 - Déterminer les variables explicatives les plus discriminantes vis-à-vis des classes déterminées;
 - Déterminer à quel groupe appartient un individu à partir de ses caractéristiques;
 - Mais surtout à valider une classification ou à faire un choix entre plusieurs classifications pour savoir laquelle est la plus pertinente.
- ✓ C'est donc une classification, mais supervisée puisqu'on connaît la réponse, les observations étant déjà affectées à un groupe. Ce qu'on souhaite savoir, c'est si ces groupes sont bien séparés et par quels critères.

Par exemple dans un hôpital, on a n patients et K diagnostics (maladies), sur chaque patient, on dispose de p analyses (mesures médicales).

On veut savoir, comment ces p mesures peuvent distinguer (discriminer) les différents diagnostics?

Quel diagnostic faut-il faire pour un nouveau patient?

C'est le rôle de l'Analyse Factorielle Discriminante (AFD), qui a un double objectif:

- ❑ Objectif descriptif et explicatif: comment les p mesures (variables quantitatives) séparent les K diagnostics (groupes)?
- ❑ Objectif prévisionnel et décisionnel: prévoir la classe d'appartenance d'un nouvel patient (individu) sur lequel, on a observé les p mesures.

L'AFD permet d'étudier le lien existant entre des variables quantitatives (mesures, analyses) et un caractère qualitatif (diagnostique). Ce dernier permet de répartir la population statistique étudiée en plusieurs classes.

2. Présentation de la méthode

Le but de la méthode, comme en ACP, est de réduire le nombre de dimensions des données, en recherchant celles suivant lesquelles les classes se séparent le mieux. Les directions factorielles discriminantes successives sont déterminées, tandis que des graphiques factoriels plans permettent ici encore de visualiser les individus ou les variables. Divers indicateurs et tests sont également calculés, qui permettent de juger de l'intérêt et de la pertinence des résultats obtenus.

2.1 Décomposition de la variance

- Calcul des moyennes et variances sur la totalité des u.s. actives
- Calcul des moyennes des variables dans chaque groupe.
- Calcul des variances des variables dans chaque groupe et de la variance des moyennes.

Définition :

Variance totale : variance calculée sur toutes les observations

Variance inter : variance des moyennes (pondérées par les effectifs des groupes)

Variance intra : moyennes des variances dans chaque groupe (id.)

$$\begin{aligned}\text{Variance totale} &= \text{variance des moyennes} + \text{moyenne des variances} \\ &= (\text{variance inter}) + (\text{variance intra})\end{aligned}$$

Les calculs doivent être effectués en pondérant les moyennes et les variances des variables de chaque groupe par les effectifs correspondants.

2.2 Définition et interprétation du rapport de corrélation

$$\text{Rapport de corrélation} = \text{variance inter} / \text{variance totale}$$

Compte tenu de l'égalité précédente, ce rapport de corrélation est compris entre 0 et 1.

Proche de 1: bonne discrimination, proche de 0: faible séparation des groupes.

Une bonne fonction discriminante devrait avoir, petite variance dans les classes, Grande variance entre les classes.

2.3 Principe de l'analyse factorielle discriminante.

Définitions

- Première composante discriminante : variable Y telle que le rapport de corrélation de Y par rapport aux groupes soit maximal.
- Deuxième composante discriminante : variable Y telle que le rapport de corrélation de Y par rapport aux groupes soit maximal, en étant non corrélée à la précédente.

- Nombre maximum de composantes discriminantes : nombre de groupes moins un, ou nombre de variables si inférieur.
- Pouvoirs discriminants : rapports de corrélation des composantes discriminantes

3. Les grandes applications

■ Le crédit scoring

- ☐ Comment identifier, a priori, les mauvais payeurs d'un crédit?

■ Médecine

- ☐ Quelles variables séparent les cas atteints d'une maladie d'une population témoin?

4. Exemple

On considère dix clients d'une banque répartis en trois groupes de risque financier : haut risque (1), risque moyen (2) et risque faible ou nul (3). On connaît pour chaque client l'âge, le revenu familial annuel, le patrimoine, et le montant de l'emprunt obtenu :

individus	âge	revenu	patrimoine	emprunt	groupe
1	45	250	1300	600	3
2	47	160	1150	450	2
3	38	165	850	370	1
4	36	175	770	250	1
5	29	99	450	400	1
6	39	170	1400	120	3
7	27	120	1400	160	2
8	51	160	1300	320	3
9	32	155	1500	350	2
10	35	177	1400	180	2

La démarche à suivre sous SPSS :

Etape 1 : la saisie des données :


Affichage des variables :

TP AFD - Editeur de données SPSS								
Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide								
								
	Nom	Type	Largeur	Décimales	Etiquette	Valeurs	Manquant	Colonnes
1	individu	Numérique	8	0		Aucun	Aucun	8
2	age	Numérique	8	0		Aucun	Aucun	8
3	revenu	Numérique	8	0		Aucun	Aucun	8
4	patrimoi	Numérique	8	0		Aucun	Aucun	8
5	emprunt	Numérique	8	0		Aucun	Aucun	8
6	groupe	Numérique	8	0		Aucun	Aucun	8
7								

Affichage des données :

TP AFD - Editeur de données SPSS							
Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide							
							
1 : individu			1				
	individu	age	revenu	patrimoi	emprunt	groupe	
1	1	45	250	1300	600	3	
2	2	47	160	1150	450	2	
3	3	38	165	850	370	1	
4	4	36	175	770	250	1	
5	5	29	99	450	400	1	
6	6	39	170	1400	120	3	
7	7	27	120	1400	160	2	
8	8	51	160	1300	320	3	
9	9	32	155	1500	350	2	
10	10	35	177	1400	180	2	
11							


Etape 2 : Analyse (la méthode pas à pas)




On obtient :




On introduit groupe dans le critère de regroupement, puis on définit l'intervalle et les variables quantitatives dans variables explicatives, on utilise **la méthode pas à pas**:



Etape 3 : Statistique :



Etape 4 : Classement :



Analyse des résultats

Une analyse discriminante se déroule en 4 étapes:

- On vérifie l'existence de différences entre les groupes;
- On vérifie la validité de l'étude;
- Estimation des coefficients de la fonction discriminante ;
- On juge la qualité de la représentation du modèle.

1) Vérification de l'existence de différences entre les sous-groupes

On vérifie s'il existe bien des différences entre les groupes grâce à trois indicateurs: La moyenne ou la variance, le test du F et le lambda de Wilks. Ils s'interprètent de la façon suivante:

	En cas d'influence	En absence d'influence
Test de F	F élevé	F faible
Lambda de Wilks	<= 0,90	Tend vers 1

Cette première analyse permet de déterminer quelles sont les variables qui sont les plus discriminantes entre les groupes.

Les moyennes et écart-types s'observent dans le tableau « Statistiques de groupe ».

Statistiques de groupe

		Moyenne	Ecart- type	N valide (liste)	
GROUPE				Non pondérées	Pondérées
1	AGE	34.33	4.73	3	3.000
	REVENU	146.33	41.30	3	3.000
	PATRIM OI	690.00	211.66	3	3.000
	EMPRUNT	340.00	79.37	3	3.000
2	AGE	35.25	8.50	4	4.000
	REVENU	153.00	23.93	4	4.000
	PATRIM OI	1362.50	149.30	4	4.000
	EMPRUNT	285.00	139.16	4	4.000
3	AGE	45.00	6.00	3	3.000
	REVENU	193.33	49.33	3	3.000
	PATRIM OI	1333.33	57.74	3	3.000
	EMPRUNT	346.67	241.11	3	3.000
Total	AGE	37.90	7.82	10	10.000
	REVENU	163.10	39.42	10	10.000
	PATRIM OI	1152.00	346.31	10	10.000
	EMPRUNT	320.00	147.27	10	10.000

Le test du F et du Lambda de Wilks s'observe dans le tableau suivant:

Tests d'égalité des moyennes des groupes

	Lambda de Wilks	F	ddl1	ddl2	Significat ion
AGE	.605	2.283	2	7	.172
REVEN U	.715	1.398	2	7	.308
PATRIMO I	.151	19.656	2	7	.001
EMPRU NT	.958	.154	2	7	.860

Variables par ordre de qualité de discrimination, la meilleur c'est celle qui a le plus grand F, ici on a Patrimoine.

Le rapport de corrélation le plus élevé est celui du patrimoine, dont le banquier tient compte de façon prépondérante dans l'évaluation du risque financier.

2) Vérification de la validité de l'étude

On estime la validité d'une analyse discriminante à partir des indicateurs:

- Le test de Box;
- La corrélation globale;
- Le Lambda de Wilks.

On observe le test de Box grâce au tableau «Résultats du test »

M de Box		2.716
F	Approximativement	1.140
	ddl1	2
	ddl2	101.606
	Signification	.324

Le M doit être le plus élevé possible. La signification du test de F doit tendre vers 0. S'il est supérieur à 0,05, l'analyse n'est pas valide.

La corrélation globale se mesure quant à elle se retrouve dans le tableau « valeurs propres ».

Fonction	Valeur propre	% de la variance	% cumulé	Corrélation canonique
1	5.616	100.0	100.0	.921

On observe notamment la colonne « corrélation canonique ». Plus est proche de 1, meilleur est le modèle.

Le Lambda Wilks s'observe quant à lui dans le tableau « Lambda de Wilks ».

Test de la ou des fonctions	Lambda de Wilks	Khi-deux	ddl	Signification
1	.151	13.227	2	.001

Plus la valeur du Lambda de Wilks est faible, plus le modèle est bon. On observe également sa significativité: plus elle tend vers 0, plus le modèle est bon.

3) Estimation des coefficients de la fonction discriminante

On observe le pouvoir discriminant des axes grâce au tableau :

Coefficients des fonctions discriminantes canoniques

	Fonction
	1
PATRIM OI	.007
(Constante)	-7.546

Coefficients non standardizes.

Ce tableau permet d'obtenir la fonction discriminante:

$$U(X) = -7,546 + 0,007 * (\text{Patrimoine}).$$

4) Qualité de la représentation

On observe la qualité de la représentation: on s'assure que la fonction discriminante classe bien les individus en sous-groupes. Pour cela, on analyse la matrice de confusion qui regroupe les individus bien classés et les mal classés.

Résultats du classement

			Classe(s) d'affectation prévue(s)			Total
		GROUPE	1	2	3	
Original	Effectif	1	3	0	0	3
		2	0	3	1	4
		3	0	1	2	3
	%	1	100.0	.0	.0	100.0
		2	.0	75.0	25.0	100.0
		3	.0	33.3	66.7	100.0
Validé-croisé	Effectif	1	3	0	0	3
		2	0	2	2	4
		3	0	1	2	3
	%	1	100.0	.0	.0	100.0
		2	.0	50.0	50.0	100.0
		3	.0	33.3	66.7	100.0

a La validation croisée n'est effectuée que pour les observations de l'analyse. Dans la validation croisée, chaque observation est classée par les fonctions dérivées de toutes les autres observations.

b 80.0% des observations originales classées correctement.


c 70.0% des observations validées-croisées classées correctement.

La note (b.) nous indique le pouvoir de reclassement de la fonction discriminante, ici 80%.


Il existe une dernière étape qui consiste à observer les mal-classés et savoir si c'est dû à un atypisme ou à une défaillance de la fonction discriminante. S'il s'agit d'un atypisme, il convient de les enlever et de recommencer l'étude.

Analyse en introduisant les variables simultanément :

Statistique :



Classement :



Résultats :

Valeurs propres

Fonction	Valeur propre	% de la variance	% cumulé	Corrélation canonique
1	10.099	93.5	93.5	.954
2	.700	6.5	100.0	.642

a Les 2 premières fonctions discriminantes canoniques ont été utilisées pour l'analyse.

Coefficients des fonctions discriminantes canoniques standardisées

	Fonction	
	1	2
AGE	.435	.801
REVENU	-.806	.670
PATRIMOIRE	1.414	-.243
EMPRUNT	.715	-.540

Donne l'équation de la fonction discriminante avec les coefficients canoniques standardisés.

Matrice de structure

	Fonction	
	1	2
PATRIMOIRE	.746	-.004
AGE	.119	.853
REVENU	.103	.647
EMPRUNT	-.032	.219

Les corrélations intra-groupes combinés entre variables discriminantes et les variables des fonctions discriminantes canoniques standardisées sont ordonnées par tailles absolues des corrélations à l'intérieur de la fonction.

* Plus grande corrélation absolue entre chaque variable et une fonction discriminante quelconque.

Classe les variables dans l'ordre de discrimination.

Fonctions aux barycentres des groupes

	Fonction	
GROUP E	1	2
1	-4.058	-4.101E-02
2	1.845	-.707
3	1.599	.983

Fonctions discriminantes canoniques non standardisées évaluées aux moyennes des groupes.

On a trois groupes, l'individu est affecté au groupe 1 ou 2 si $U(x) < 0$

Diagnostic des observations

Diagnostic des observations

Ni	Groupe effectif	Plus grand groupe					Deuxième plus grand groupe			Scores discriminants	
		Groupe prévu	P(D>d G=g)		P(G=g D=d)	Carré de la distance de Mahalanobis au barycentre	Groupe	P(G=g D=d)	Carré de la distance de Mahalanobis au barycentre	Fonction 1	Fonction 2
			p	ddl							
1	3	3	,898	2	,873	,216	2	,127	4,077	1,190	1,203
2	2	3**	,846	2	,704	,334	2	,296	2,072	1,189	,575
3	1	1	,324	2	1,000	2,253	3	,000	18,119	-2,612	,361
4	1	1	,675	2	1,000	,785	3	,000	33,849	-4,217	,831
5	1	1	,194	2	1,000	3,280	2	,000	52,068	-5,345	-1,315
6	3	3	,868	2	,675	,283	2	,325	1,745	1,344	,516
7	2	2	,493	2	,970	1,415	3	,030	8,342	1,829	-1,896
8	3	3	,778	2	,847	,501	2	,153	3,924	2,262	1,230
9	2	2	,314	2	,957	2,319	3	,043	8,503	3,155	-1,483
10	2	2	,645	2	,536	,877	3	,464	1,166	1,205	-,023

** .Observation mal classée

Dans la section « Groupe prévu », on constate que observation « 2 » passe du groupe « 2 » au groupe « 3 »; l'analyse discriminante a détecté que cette observation était "mal classée".

- D et d valeur de la fonction discriminante U (théorique:D, Observée:d);
- $P(G=g|D=d)$ =probabilité que l'individu appartient au groupe g sachant que D=d;
- On calcule cette probabilité pour g=1, 2 et 3. on met la plus grande dans la colonne 6 et la plus petite dans la colonne 9; Le groupe prévu est celui qui correspond à la plus grande probabilité (c'est aussi celui qui a la plus petite distance de Mahalanobis (colonne 7)).

Classement des individus

On obtient les coordonnées de chaque individu sur chaque axe factoriel discriminant :

TP AFD - Editeur de données SPSS									
Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide									
1 : individu		1							
	individu	age	revenu	patrimoi	emprunt	groupe	dis1_1	dis2_1	
1	1	45	250	1300	600	3	1.18963	1.20335	
2	2	47	160	1150	450	2	1.18944	.57481	
3	3	38	165	850	370	1	-2.61240	.36140	
4	4	36	175	770	250	1	-4.21740	.83086	
5	5	29	99	450	400	1	-5.34525	-1.31529	
6	6	39	170	1400	120	3	1.34414	.51604	
7	7	27	120	1400	160	2	1.82935	-1.89595	
8	8	51	160	1300	320	3	2.26197	1.22994	
9	9	32	155	1500	350	2	3.15518	-1.48256	
10	10	35	177	1400	180	2	1.20534	-.02262	
11									

Graphique :

TP AFD - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide

1 : individu 1

	individu	age	revenu	patrim
1	1	45	250	1
2	2	47	160	1
3	3	38	165	
4	4	36	175	
5	5	29	99	
6	6	39	170	1
7	7	27	120	1
8	8	51	160	1
9	9	32	155	1
10	10	35	177	1
11				
12				
13				
14				
15				

Graphes

- Galerie
- Interactif
- Bâtons...
- Courbes...
- Aires ...
- Secteurs...
- Cycle...
- Pareto...
- Contrôle...
- Boîte à moustaches...
- Barre d'erreur...
- Diagramme de dispersion...**
- Histogramme...
- P-P...
- Q-Q...
- Diagramme séquentiel...
- Courbe ROC...
- Séries chronologiques

	dis1_1	dis2_1
1	1.18963	1.20335
2	1.18944	.57481
3	-2.61240	.36140
4	-4.21740	.83086
5	-5.34525	-1.31529
6	1.34414	.51604
7	1.82935	-1.89595
8	2.26197	1.22994
9	3.15518	-1.48256
10	1.20534	-.02262
11		
12		
13		
14		
15		

TP AFD - Editeur de données SPSS

Fichier Edition Affichage Données Transformer Analyse Graphes Outils Fenêtre Aide



1 : individu 1

	individu	age	revenu	patrimoi	emprunt	groupe	dis1_1	dis2_1	var
1	1	45	250	1300	600	3	1.18963	1.20335	
2	2	47	160	1150	450	2	1.18944	.57481	
3	3	38	165	850	370	1	-2.61240	.36140	
4	4	36	175	770	250	1	-4.21740	.83086	
5	5	29	99	450	400	1	-5.34525	-1.31529	
6	6	39	170	1400	120	3	1.34414	.51604	
7	7	27	120	1400	160	2	1.82935	-1.89595	
8	8	51	160	1300	320	3	2.26197	1.22994	
9	9	32	155	1500	350	2	3.15518	-1.48256	
10	10	35	177	1400					
11									
12									
13									
14									
15									
16									
17									

Diagramme de dispersion

Simple Matrice Superposé 3D

Définir Annuler Aide



On a presque quatre groupes d'individus.