

Cours complet d'Analyse en Composantes Principales (ACP) avec multiples exemples pratiques

DUT : GI-SIR-IDIA / ESTBM USMS

Pr. Abdelaziz QAFFOU

Table des matières

1	Introduction générale à l'ACP	3
1.1	Histoire et fondements	3
1.2	Principes mathématiques	3
2	Exemple 1 : Données économiques - USArrests	3
2.1	Description du dataset	3
2.2	ACP sans standardisation	3
2.3	ACP avec standardisation	4
2.4	Interprétation	4
3	Exemple 2 : Données génétiques - ADN	5
3.1	Simulation de données génétiques	5
3.2	ACP sur données génétiques	8
3.3	Interprétation des résultats génétiques	8
4	Exemple 3 : Données marketing - Satisfaction clients	8
4.1	Simulation de données marketing	8
4.2	ACP pour segmenter les clients	10
5	Exemple 4 : Données financières - Indices boursiers	10
5.1	Données de marché financier	10
5.2	ACP pour l'allocation d'actifs	11
6	Exemple 5 : Données d'images - Réduction de dimension	12
6.1	ACP sur des images (visages)	12
7	Exercices pratiques	14
7.1	Exercice 1 : Données de consommation	14
7.2	Exercice 2 : Données écologiques	14
7.3	Exercice 3 : ACP incrémentale	14

8	Bonnes pratiques et pièges à éviter	15
8.1	Préparation des données	15
8.2	Choix du nombre de composantes	15
9	Extensions de l'ACP	16
9.1	Variantes de l'ACP	16
9.2	Packages R avancés	16
10	Conclusion	17
10.1	Pour aller plus loin	17
A	Annexe : Formules mathématiques détaillées	18
A.1	Décomposition en valeurs singulières	18
A.2	Projection et reconstruction	18

1 Introduction générale à l'ACP

L'Analyse en Composantes Principales (ACP) est une méthode de réduction de dimensionnalité qui transforme un ensemble de variables corrélées en un ensemble plus petit de variables non corrélées appelées composantes principales.

1.1 Histoire et fondements

- Inventée par Karl Pearson en 1901
- Développée par Harold Hotelling dans les années 1930
- Applications en psychométrie, biologie, finance, marketing

1.2 Principes mathématiques

Soit X une matrice $n \times p$ centrée. On cherche $Y = XW$ où W est une matrice de poids telle que :

1. Les composantes sont non corrélées : $Cov(Y_i, Y_j) = 0$ pour $i \neq j$
2. La variance est maximisée pour la première composante
3. Chaque composante successive maximise la variance restante

2 Exemple 1 : Données économiques - USArrests

2.1 Description du dataset

Le dataset `USArrests` contient des statistiques d'arrestations par État aux USA en 1973.

Listing 1 – Exploration des données `USArrests`

```
1 # Chargement des données
2 data("USArrests")
3 head(USArrests)
4
5 # Dimensions
6 dim(USArrests)
7
8 # Résumé statistique
9 summary(USArrests)
10
11 # Vérification des données manquantes
12 sum(is.na(USArrests))
```

2.2 ACP sans standardisation

Listing 2 – ACP non normée sur `USArrests`

```
1 # ACP sans standardisation (données brutes)
2 acp_raw <- prcomp(USArrests, center = TRUE, scale. = FALSE)
3
```

TABLE 1 – Extrait des données USArrests

État	Meurtre	Agression	Population Urbaine	Viol
Alabama	13.2	236	58	21.2
Alaska	10.0	263	48	44.5
Arizona	8.1	294	80	31.0
Arkansas	8.8	190	50	19.5
California	9.0	276	91	40.6
Colorado	7.9	204	78	38.7

```

4 # Résumé
5 summary(acp_raw)
6
7 # Affichage des résultats
8 print(acp_raw)
9
10 # Visualisation
11 biplot(acp_raw, main = "ACP non normée - USArrests")

```

2.3 ACP avec standardisation

Listing 3 – ACP normée sur USArrests

```

1 # ACP avec standardisation (recommandée)
2 acp_scaled <- prcomp(USArrests, center = TRUE, scale. = TRUE)
3
4 # Résumé
5 summary(acp_scaled)
6
7 # Valeurs propres
8 acp_scaled$sdev^2
9
10 # Pourcentage de variance expliquée
11 prop_var <- acp_scaled$sdev^2 / sum(acp_scaled$sdev^2)
12 cumsum(prop_var)
13
14 # Graphiques avec factoextra
15 library(factoextra)
16 fviz_eig(acp_scaled, addlabels = TRUE)
17 fviz_pca_var(acp_scaled, col.var = "contrib")
18 fviz_pca_ind(acp_scaled, label = "none")

```

2.4 Interprétation

- **PC1 (62%)** : Contraste entre criminalité violente et population urbaine
- **PC2 (24.7%)** : Opposition entre meurtre/agression et viol
- Les 2 premières composantes expliquent 86.7% de la variance

TABLE 2 – Résultats de l'ACP normée sur USArrests

Composante	Valeur propre	Variance (%)	Variance cumulée (%)
PC1	2.480	62.0	62.0
PC2	0.990	24.7	86.7
PC3	0.357	8.9	95.6
PC4	0.173	4.4	100.0

3 Exemple 2 : Données génétiques - ADN

3.1 Simulation de données génétiques

Listing 4 – Simulation de données génétiques

```

1  # Simulation de données génétiques
2  set.seed(123)
3  n_individus <- 100
4  n_genes <- 50
5
6  # Création de groupes génétiques
7  groupe <- rep(c("A", "B", "C"), length.out = n_individus)
8
9  # Simulation d'expression génétique avec corrélations
10 library(MASS)
11
12 # Matrice de covariance
13 sigma <- matrix(0.7, n_genes, n_genes)
14 diag(sigma) <- 1
15
16 # Ajout de structure de groupe
17 for(i in 1:3) {
18   start <- (i-1)*15 + 1
19   end <- i*15
20   sigma[start:end, start:end] <- 0.9
21 }
22
23 # Génération des données
24 expression <- mvrnorm(n_individus, mu = rep(0, n_genes),
25   Sigma = sigma)
26
27 # Ajout d'effets groupe
28 expression[groupe == "A", 1:15] <- expression[groupe == "A",
29   1:15] + 1
30 expression[groupe == "B", 16:30] <- expression[groupe ==
31   "B", 16:30] + 1
32 expression[groupe == "C", 31:45] <- expression[groupe ==
33   "C", 31:45] + 1
34
35 # Noms des gènes

```

```
32     colnames(expression) <- paste0("Gene_", sprintf("%02d",
33         1:n_genes))
34     rownames(expression) <- paste0("Ind_", sprintf("%03d",
35         1:n_individus))
36
37     # Création du data.frame
38     donnees_adn <- data.frame(Groupe = groupe, expression)
```

TABLE 3 – Extrait des données d’expression génétique simulées

Individu	Groupe	Gene_01	Gene_02	Gene_03	Gene_04	Gene_05	Gene_06	Gene_07	Gene_08	Gene_09
Ind_001	A	2.31	1.98	1.76	1.54	1.89	0.12	-0.23	0.45	-0.67
Ind_002	B	-0.45	0.23	0.67	-0.12	0.89	2.34	1.87	2.01	1.76
Ind_003	C	0.12	-0.45	-0.23	0.67	0.34	-0.56	0.89	-0.12	1.23
Ind_004	A	1.89	2.34	1.67	2.01	1.76	0.45	0.12	0.67	-0.23
Ind_005	B	0.34	0.89	0.12	1.23	0.56	1.89	2.34	1.67	2.01

3.2 ACP sur données génétiques

Listing 5 – ACP sur données génétiques

```
1 # ACP sur les données d'expression
2 acp_adn <- prcomp(expression, center = TRUE, scale. = TRUE)
3
4 # Graphique des valeurs propres
5 fviz_eig(acp_adn,
6 ncp = 20,
7 addlabels = TRUE,
8 barfill = "#4CAF50",
9 barcolor = "#4CAF50")
10
11 # Graphique des individus colorés par groupe
12 fviz_pca_ind(acp_adn,
13 col.ind = groupe,
14 palette = c("#FF5722", "#2196F3", "#4CAF50"),
15 addEllipses = TRUE,
16 ellipse.level = 0.95,
17 legend.title = "Groupe")
18
19 # Contribution des variables (gènes)
20 fviz_contrib(acp_adn, choice = "var", axes = 1, top = 20)
21 fviz_contrib(acp_adn, choice = "var", axes = 2, top = 20)
22
23 # Biplot (limité aux gènes les plus contributifs)
24 fviz_pca_biplot(acp_adn,
25 col.ind = groupe,
26 col.var = "contrib",
27 gradient.cols = c("blue", "yellow", "red"),
28 select.var = list(contrib = 10),
29 repel = TRUE)
```

3.3 Interprétation des résultats génétiques

4 Exemple 3 : Données marketing - Satisfaction clients

4.1 Simulation de données marketing

Listing 6 – Simulation de données de satisfaction

```
1 # Simulation de données marketing
2 set.seed(456)
3 n_clients <- 200
4
5 # Variables de satisfaction (échelle 1-10)
6 satisfaction <- data.frame(
7 Client = paste0("Client_", sprintf("%03d", 1:n_clients)),
8 Qualite = round(rnorm(n_clients, 7, 1.5), 1),
9 Prix = round(rnorm(n_clients, 6, 2), 1),
```


TABLE 4 – Gènes les plus contributifs à la première composante

Rang	Gène	Contribution (%)
1	Gene_04	3.2
2	Gene_07	3.1
3	Gene_12	3.0
4	Gene_01	2.9
5	Gene_09	2.8
6	Gene_15	2.7
7	Gene_03	2.6
8	Gene_10	2.5
9	Gene_06	2.4
10	Gene_13	2.3

```

10 Service = round(rnorm(n_clients, 8, 1.2), 1),
11 Livraison = round(rnorm(n_clients, 7.5, 1.8), 1),
12 Design = round(rnorm(n_clients, 7.8, 1.4), 1),
13 Recommandation = round(rnorm(n_clients, 8.2, 1.1), 1)
14 )
15
16 # Ajout de corrélations
17 library(corpcor)
18 # Matrice de corrélation souhaitée
19 cor_target <- matrix(c(
20 1.0, -0.3, 0.8, 0.6, 0.7, 0.9,
21 -0.3, 1.0, -0.2, -0.4, -0.1, -0.3,
22 0.8, -0.2, 1.0, 0.7, 0.6, 0.8,
23 0.6, -0.4, 0.7, 1.0, 0.5, 0.6,
24 0.7, -0.1, 0.6, 0.5, 1.0, 0.7,
25 0.9, -0.3, 0.8, 0.6, 0.7, 1.0
26 ), nrow = 6)
27
28 # Génération de données corrélées
29 satisfaction_cor <- mvrnorm(n_clients,
30 mu = rep(0, 6),
31 Sigma = cor_target)
32
33 # Transformation en échelle 1-10
34 satisfaction_cor <- apply(satisfaction_cor, 2, function(x) {
35   round((x - min(x)) / (max(x) - min(x)) * 9 + 1, 1)
36 })
37
38 colnames(satisfaction_cor) <- c("Qualite", "Prix", "Service",
39 "Livraison", "Design", "Recommandation")
40
41 donnees_marketing <- data.frame(
42 Client = satisfaction$Client,
43 satisfaction_cor
44 )

```

4.2 ACP pour segmenter les clients

Listing 7 – ACP marketing

```
1 # ACP sur les données marketing
2 acp_marketing <- PCA(donnees_marketing[, -1], graph = FALSE)
3
4 # Visualisations
5 fviz_eig(acp_marketing,
6 addlabels = TRUE,
7 ylim = c(0, 60),
8 main = "Variance expliquée - Satisfaction clients")
9
10 # Cercle des corrélations
11 fviz_pca_var(acp_marketing,
12 col.var = "cos2",
13 gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
14 repel = TRUE,
15 title = "Cercle des corrélations - Variables de
16         satisfaction")
17
18 # Classification hiérarchique sur les composantes principales
19 # Récupération des coordonnées des individus
20 coord_ind <- acp_marketing$ind$coord[, 1:3]
21
22 # Clustering k-means sur les 3 premières composantes
23 set.seed(789)
24 kmeans_result <- kmeans(coord_ind, centers = 4, nstart = 25)
25
26 # Visualisation avec couleurs selon clusters
27 fviz_pca_ind(acp_marketing,
28 col.ind = as.factor(kmeans_result$cluster),
29 palette = c("#FF6B6B", "#4ECDC4", "#45B7D1", "#96CEB4"),
30 addEllipses = TRUE,
31 ellipse.type = "confidence",
32 legend.title = "Segment",
33 title = "Segmentation des clients")
```

5 Exemple 4 : Données financières - Indices boursiers

5.1 Données de marché financier

Listing 8 – Analyse de données financières

```
1 # Chargement de données financières
2 library(quantmod)
3
4 # Récupération des données boursières
5 symbols <- c("^GSPC", "^IXIC", "^DJI", "EURUSD=X", "GC=F",
6             "CL=F")
```

TABLE 5 – Caractérisation des segments clients

Segment	Taille	Satisfaction moyenne	Valeur client	Caractéristiques
Fidèles	52	8.7	Élevée	Très satisfaits, recommandent, peu sensibles au prix
Exigeants	48	7.2	Moyenne	Exigeants sur la qualité, sensibles au prix
Indifférents	62	6.5	Faible	Peu engagés, satisfaction moyenne
Mécontents	38	4.8	Négative	Insatisfaits, ne recommandent pas

```

7  getSymbols(symbols,
8  from = "2022-01-01",
9  to = "2023-12-31",
10 src = "yahoo")
11
12 # Extraction des prix de clôture
13 data_fin <- merge(Cl(GSPC), Cl(IXIC), Cl(DJI),
14 Cl('EURUSD=X'), Cl('GC=F'), Cl('CL=F'))
15
16 # Nettoyage des noms
17 colnames(data_fin) <- c("SP500", "NASDAQ", "DJIA",
18 "EURUSD", "Gold", "Oil")
19
20 # Calcul des rendements journaliers
21 returns <- na.omit(diff(log(data_fin)))
22
23 # Statistiques descriptives
24 summary(returns)
25
26 # Matrice de corrélation
27 cor_matrix <- cor(returns)
28 print(round(cor_matrix, 3))
29
30 # Visualisation des corrélations
31 library(corrplot)
32 corrplot(cor_matrix,
33 method = "color",
34 type = "upper",
35 tl.col = "black",
36 tl.srt = 45)

```

5.2 ACP pour l'allocation d'actifs

Listing 9 – ACP financière

```

1  # ACP sur les rendements

```

```

2  acp_fin <- PCA(as.data.frame(returns), graph = FALSE)
3
4  # Analyse des résultats
5  print(acp_fin$eig)
6
7  # Visualisation
8  fviz_eig(acp_fin,
9  addlabels = TRUE,
10 main = "Variance expliquée - Rendements financiers")
11
12 # Variables
13 fviz_pca_var(acp_fin,
14 col.var = "contrib",
15 gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
16 repel = TRUE,
17 title = "Contributions des actifs financiers")
18
19 # Individus (jours de trading)
20 fviz_pca_ind(acp_fin,
21 col.ind = "cos2",
22 gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),
23 repel = TRUE,
24 title = "Jours de trading selon les composantes principales")
25
26 # Identification des jours extrêmes (marchés volatils)
27 cos2_ind <- acp_fin$ind$cos2[, 1] + acp_fin$ind$cos2[, 2]
28 jours_extremes <- which(cos2_ind > quantile(cos2_ind, 0.95))
29 dates_extremes <- index(returns)[jours_extremes]

```

TABLE 6 – Composantes principales des rendements financiers

Actif	PC1	PC2	Cos $\hat{s}$ PC1	Contribution (%)
SP500	0.45	-0.32	0.20	25.1
NASDAQ	0.48	-0.28	0.23	28.8
DJIA	0.42	-0.35	0.18	22.1
EURUSD	0.23	0.65	0.05	6.8
Gold	0.35	0.41	0.12	15.3
Oil	0.42	0.33	0.18	22.5

6 Exemple 5 : Données d'images - Réduction de dimension

6.1 ACP sur des images (visages)

Listing 10 – ACP pour la reconnaissance faciale

```

1  # Exemple simplifié avec des images synthétiques

```

```

2  # Génération de visages aléatoires
3  set.seed(1234)
4  n_visages <- 100
5  largeur <- 32
6  hauteur <- 32
7  pixels <- largeur * hauteur
8
9  # Création de visages de base
10 visages <- matrix(rnorm(n_visages * pixels, mean = 128, sd =
11   30),
12   nrow = n_visages, ncol = pixels)
13
14 # Ajout de structures communes (yeux, bouche)
15 for(i in 1:n_visages) {
16   # Yeux
17   yeux_gauche <- sample(600:800, 1)
18   yeux_droit <- sample(1000:1200, 1)
19   visages[i, yeux_gauche:(yeux_gauche+50)] <-
20   rnorm(51, mean = 200, sd = 10)
21   visages[i, yeux_droit:(yeux_droit+50)] <-
22   rnorm(51, mean = 200, sd = 10)
23
24   # Bouche
25   bouche <- sample(1800:2000, 1)
26   visages[i, bouche:(bouche+100)] <-
27   rnorm(101, mean = 100, sd = 15)
28 }
29
30 # Normalisation entre 0 et 255
31 visages <- apply(visages, 1, function(x) {
32   x <- (x - min(x)) / (max(x) - min(x)) * 255
33 })
34
35 visages <- t(visages)
36
37 # ACP sur les images
38 acp_visages <- prcomp(visages, center = TRUE, scale. = TRUE)
39
40 # Visualisation des composantes principales (eigenfaces)
41 par(mfrow = c(3, 4))
42 for(i in 1:12) {
43   image(matrix(acp_visages$rotation[, i], largeur, hauteur),
44     main = paste("Eigenface", i),
45     col = gray.colors(256))
46 }
47 par(mfrow = c(1, 1))
48
49 # Reconstruction avec différentes composantes
50 individu_test <- 1
51 n_composantes <- c(5, 10, 20, 50, 100, 300)

```

```

52 par(mfrow = c(2, 3))
53 for(n in n_composantes) {
54   # Reconstruction
55   reconstruction <- acp_visages$x[individu_test, 1:n] %*%
56   t(acp_visages$rotation[, 1:n])
57
58   image(matrix(reconstruction, largeur, hauteur),
59         main = paste(n, "composantes"),
60         col = gray.colors(256))
61 }
62 par(mfrow = c(1, 1))

```

TABLE 7 – Qualité de reconstruction des images

Nombre de composantes	Variance expliquée (%)	Erreur de reconstruction
5	45.2	0.78
10	62.7	0.52
20	78.3	0.31
50	92.1	0.12
100	98.7	0.03
300	100.0	0.00

7 Exercices pratiques

7.1 Exercice 1 : Données de consommation

1. Télécharger le dataset `food` du package `FactoMineR`
2. Analyser la structure des corrélations entre les aliments
3. Réaliser une ACP et interpréter les composantes
4. Identifier les profils de consommation

7.2 Exercice 2 : Données écologiques

1. Utiliser le dataset `mtcars`
2. Réaliser une ACP sur les caractéristiques techniques
3. Interpréter les composantes en termes de performance
4. Classifier les voitures selon leurs caractéristiques

7.3 Exercice 3 : ACP incrémentale

1. Simuler un flux de données avec 1000 nouvelles observations
2. Implémenter une ACP incrémentale
3. Comparer avec une ACP classique
4. Évaluer la stabilité des composantes

Listing 11 – Solution exercice 2

```

1  # Exercice 2: ACP sur mtcars
2  data(mtcars)
3
4  # Préparation des données
5  mtcars_scaled <- scale(mtcars)
6
7  # ACP
8  acp_mtcars <- PCA(mtcars_scaled, graph = FALSE)
9
10 # Visualisation
11 fviz_eig(acp_mtcars, addlabels = TRUE)
12 fviz_pca_var(acp_mtcars, col.var = "contrib")
13 fviz_pca_ind(acp_mtcars,
14 col.ind = mtcars$mpg,
15 gradient.cols = c("blue", "yellow", "red"),
16 label = "none")
17
18 # Interprétation
19 # PC1: Puissance vs Économie de carburant
20 # PC2: Poids et dimensions

```

8 Bonnes pratiques et pièges à éviter

8.1 Préparation des données

TABLE 8 – Checklist de préparation des données pour l'ACP

Étape	Action	Statut
1	Vérifier les données manquantes	
2	Standardiser les variables si échelles différentes	
3	Vérifier la linéarité des relations	
4	Examiner les corrélations bivariées	
5	Détecter et traiter les outliers	
6	Vérifier l'adéquation des données (test de Bartlett)	
7	Calculer le KMO (Kaiser-Meyer-Olkin)	

8.2 Choix du nombre de composantes

1. **Critère de Kaiser** : valeurs propres > 1
2. **Scree plot** : point d'inflexion
3. **Variance expliquée** : seuil subjectif (80-95%)
4. **Parallèle analysis** : comparaison avec données aléatoires

Listing 12 – Parallèle analysis pour choix de composantes

```

1  # Fonction pour analyse parallèle
2  parallel_analysis <- function(data, n_sim = 100) {
3    n <- nrow(data)
4    p <- ncol(data)
5
6    # Valeurs propres observées
7    eigen_obs <- prcomp(data, scale. = TRUE)$sdev^2
8
9    # Valeurs propres simulées
10   eigen_sim <- matrix(0, n_sim, p)
11
12   for(i in 1:n_sim) {
13     # Données aléatoires avec même dimension
14     data_sim <- matrix(rnorm(n * p), n, p)
15     eigen_sim[i, ] <- prcomp(data_sim, scale. = TRUE)$sdev^2
16   }
17
18   # Percentile 95
19   eigen_critique <- apply(eigen_sim, 2, quantile, 0.95)
20
21   # Nombre à retenir
22   n_retain <- sum(eigen_obs > eigen_critique)
23
24   return(list(
25     observed = eigen_obs,
26     critical = eigen_critique,
27     n_components = n_retain
28   ))
29 }
30
31 # Application
32 pa_result <- parallel_analysis(iris[, 1:4])
33 print(pa_result$n_components)

```

9 Extensions de l'ACP

9.1 Variantes de l'ACP

9.2 Packages R avancés

Listing 13 – Packages R pour l'ACP avancée

```

1  # Packages spécialisés
2  # install.packages(c("ade4", "mixOmics", "missMDA",
3    "pcaMethods", "rpca"))
4
5  library(ade4)           # ACP avec supplémentaire
6  library(mixOmics)       # ACP multitable
7  library(missMDA)        # ACP avec données manquantes

```


TABLE 9 – Variantes de l’ACP et leurs applications

Méthode	Description	Application
ACP normée	Standardisation des variables	Variables d’échelles différentes
ACP non normée	Sans standardisation	Variables de même unité
ACP robuste	Résistante aux outliers	Données contaminées
ACP incrémentale	Mise à jour en ligne	Flux de données
ACP sparse	Sélection de variables	Haute dimension
ACP kernel	Version non linéaire	Données complexes
ACP multitable	Plusieurs tables	Données multivues

```

7  library(pcaMethods) # Méthodes variées d’ACP
8  library(rpca)       # ACP robuste
9
10 # Exemple avec ACP robuste
11 library(rpca)
12 acp_robuste <- rpca(USArrests, center = TRUE, scale = TRUE)
13 summary(acp_robuste)
14
15 # ACP avec données manquantes
16 library(missMDA)
17 # Simulation de données manquantes
18 data_manquantes <- USArrests
19 data_manquantes[sample(1:200, 20)] <- NA
20
21 # Imputation puis ACP
22 acp_imputed <- imputePCA(data_manquantes, ncp = 2)
23 PCA(acp_imputed$completeObs, graph = FALSE)

```

10 Conclusion

L’ACP est une méthode fondamentale avec des applications dans presque tous les domaines. Ce cours a montré :

- Les fondements mathématiques de l’ACP
- 5 exemples concrets avec interprétation
- Des techniques avancées et variantes
- Des exercices pratiques pour consolider les connaissances

10.1 Pour aller plus loin

1. **ACP en Python** : `sklearn.decomposition.PCA`
2. **ACP en ligne** : Big Data et streaming
3. **ACP interactive** : Applications Shiny
4. **Validation croisée** : Pour choisir le nombre de composantes

Références

- [1] Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer.
- [2] Abdi, H., & Williams, L. J. (2010). *Principal component analysis*. Wiley Interdisciplinary Reviews : Computational Statistics.
- [3] Husson, F., Lê, S., & Pagès, J. (2017). *Exploratory Multivariate Analysis by Example Using R*. CRC Press.
- [4] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.

A Annexe : Formules mathématiques détaillées

A.1 Décomposition en valeurs singulières

L'ACP peut être formulée via la Décomposition en Valeurs Singulières (SVD) :

$$X = U\Sigma V^T$$

où :

- U : matrice des vecteurs singuliers à gauche (individus)
- Σ : matrice diagonale des valeurs singulières
- V : matrice des vecteurs singuliers à droite (variables)

Les composantes principales sont données par $U\Sigma$.

A.2 Projection et reconstruction

La projection sur k composantes :

$$X_k = U_k \Sigma_k V_k^T$$

L'erreur de reconstruction :

$$\|X - X_k\|_F^2 = \sum_{i=k+1}^p \sigma_i^2$$