

Analyse Factorielle des Correspondances (AFC)

Guide théorique et exemple pratique

DUT : GI-SIR-IDIA / ESTBM USMS

Pr. Abdelaziz QAFFOU

Résumé

L'Analyse Factorielle des Correspondances (AFC) est une méthode statistique d'analyse des données qui permet d'étudier les relations entre deux variables qualitatives. Ce document présente les fondements théoriques de l'AFC et illustre son application à travers un exemple pratique complet. Nous expliquons les étapes de calcul, l'interprétation des résultats et fournissons le code nécessaire pour réaliser cette analyse avec des logiciels statistiques courants.

Table des matières

1	Introduction à l'AFC	3
1.1	Définition et objectifs	3
1.2	Domaine d'application	3
2	Fondements mathématiques	3
2.1	Le tableau de contingence	3
2.2	Le tableau des profils	3
2.3	La distance du chi-deux	4
2.4	Décomposition en valeurs singulières	4
3	Exemple pratique	4
3.1	Présentation des données	4
3.2	Calculs préliminaires	4
3.2.1	Tableau des profils lignes	4
3.2.2	Tableau des profils colonnes	5
3.3	Calcul de l'AFC	5
3.3.1	Étape 1 : Tableau des écarts à l'indépendance	5
3.3.2	Étape 2 : Calcul de la matrice Z	6
3.3.3	Étape 3 : Décomposition en valeurs singulières (SVD)	6

3.3.4	Étape 4 : Coordonnées factorielles	6
3.3.5	Étape 5 : Contributions et cosinus carrés	7
4	Interprétation des résultats	7
4.1	Représentation graphique	7
4.2	Interprétation des axes	7
4.2.1	Axe 1 (77.5% de l'inertie)	7
4.2.2	Axe 2 (17.4% de l'inertie)	8
4.3	Synthèse	8
5	Implémentation avec R et Python	8
5.1	Implémentation avec R	8
5.2	Implémentation avec Python	9
6	Conclusion	10
7	Références	11
A	Annexe : Formules complètes	11
A.1	Inertie totale	11
A.2	Test du chi-deux	11

1 Introduction à l'AFC

1.1 Définition et objectifs

L'Analyse Factorielle des Correspondances (AFC) est une technique d'analyse exploratoire des données développée par Jean-Paul Benzécri dans les années 1960. Elle s'applique à des tableaux de contingence qui croisent deux variables qualitatives (ou catégorielles).

L'objectif principal de l'AFC est de :

- Analyser les associations entre les modalités de deux variables qualitatives
- Représenter graphiquement ces associations dans un espace de dimension réduite
- Identifier les structures sous-jacentes dans les données
- Détecter les modalités qui contribuent le plus aux associations observées

1.2 Domaine d'application

L'AFC est particulièrement utile dans les domaines suivants :

- Sciences sociales (étude des préférences, comportements)
- Marketing (analyse des segments de clientèle)
- Linguistique (analyse textuelle, lexicométrie)
- Biologie (écologie des espèces)
- Sciences de l'information (bibliométrie)

2 Fondements mathématiques

2.1 Le tableau de contingence

Soit un tableau de contingence $\mathbf{N} = (n_{ij})$ de dimensions $I \times J$ où :

- n_{ij} est l'effectif observé pour la modalité i de la première variable et la modalité j de la seconde variable
- $n_{i\cdot} = \sum_{j=1}^J n_{ij}$ est la marge ligne i
- $n_{\cdot j} = \sum_{i=1}^I n_{ij}$ est la marge colonne j
- $n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}$ est l'effectif total

2.2 Le tableau des profils

À partir du tableau de contingence, on définit :

- Le tableau des fréquences relatives : $\mathbf{P} = (p_{ij}) = \left(\frac{n_{ij}}{n}\right)$
- Les profils lignes : $p_{i|j} = \frac{n_{ij}}{n_{i\cdot}}$
- Les profils colonnes : $p_{j|i} = \frac{n_{ij}}{n_{\cdot j}}$
- Les masses (poids) : $r_i = \frac{n_{i\cdot}}{n}$ et $c_j = \frac{n_{\cdot j}}{n}$

2.3 La distance du chi-deux

La métrique utilisée en AFC est la distance du chi-deux entre les profils. Pour deux profils lignes i et i' , cette distance s'exprime comme :

$$d^2(i, i') = \sum_{j=1}^J \frac{1}{c_j} \left(\frac{n_{ij}}{n_{i.}} - \frac{n_{i'j}}{n_{i'.}} \right)^2$$

De même, pour deux profils colonnes j et j' :

$$d^2(j, j') = \sum_{i=1}^I \frac{1}{r_i} \left(\frac{n_{ij}}{n_{.j}} - \frac{n_{ij'}}{n_{.j'}} \right)^2$$

2.4 Décomposition en valeurs singulières

L'AFC repose sur la décomposition en valeurs singulières (SVD) de la matrice des écarts à l'indépendance :

$$\mathbf{Z} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{r}\mathbf{c}^T)\mathbf{D}_c^{-1/2}$$

où $\mathbf{D}_r$ et $\mathbf{D}_c$ sont les matrices diagonales des masses lignes et colonnes.

La SVD de $\mathbf{Z}$ donne :

$$\mathbf{Z} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^T$$

avec :

- $\mathbf{U}$: matrice des vecteurs singuliers lignes ($\mathbf{U}^T\mathbf{D}_r\mathbf{U} = \mathbf{I}$)
- $\mathbf{V}$: matrice des vecteurs singuliers colonnes ($\mathbf{V}^T\mathbf{D}_c\mathbf{V} = \mathbf{I}$)
- $\mathbf{\Lambda}$: matrice diagonale des valeurs singulières ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_K$)

3 Exemple pratique

3.1 Présentation des données

Considérons une étude sur les préférences musicales selon l'âge. Nous avons interrogé 200 personnes et obtenu le tableau de contingence suivant :

3.2 Calculs préliminaires

3.2.1 Tableau des profils lignes

Calculons d'abord les profils lignes (proportions par ligne) :

TABLE 1 – Tableau de contingence : Préférences musicales selon l'âge

	Classique	Rock	Pop	Jazz	Total
15-25 ans	10	35	30	5	80
26-40 ans	15	20	25	20	80
41-60 ans	25	5	10	25	65
61+ ans	30	0	5	20	55
Total	80	60	70	70	280

TABLE 2 – Profils lignes (en proportions)

	Classique	Rock	Pop	Jazz
15-25 ans	0.125	0.4375	0.375	0.0625
26-40 ans	0.1875	0.25	0.3125	0.25
41-60 ans	0.3846	0.0769	0.1538	0.3846
61+ ans	0.5455	0	0.0909	0.3636

3.2.2 Tableau des profils colonnes

De même, les profils colonnes (proportions par colonne) :

TABLE 3 – Profils colonnes (en proportions)

	Classique	Rock	Pop	Jazz
15-25 ans	0.125	0.5833	0.4286	0.0714
26-40 ans	0.1875	0.3333	0.3571	0.2857
41-60 ans	0.3125	0.0833	0.1429	0.3571
61+ ans	0.375	0	0.0714	0.2857

3.3 Calcul de l'AFC

3.3.1 Étape 1 : Tableau des écarts à l'indépendance

Sous l'hypothèse d'indépendance, la fréquence théorique serait :

$$p_{ij}^{\text{théorique}} = r_i \times c_j$$

avec $r_i = \frac{n_{i.}}{n}$ et $c_j = \frac{n_{.j}}{n}$.

Les masses lignes sont : $r = (0.2857, 0.2857, 0.2321, 0.1964)$

Les masses colonnes sont : $c = (0.2857, 0.2143, 0.2500, 0.2500)$

Le tableau des écarts à l'indépendance (différence entre fréquences observées et théoriques) est :

$$\mathbf{P} - \mathbf{rc}^T = \begin{pmatrix} -0.0306 & 0.0714 & 0.0214 & -0.0622 \\ -0.0051 & 0.0051 & -0.0000 & 0.0000 \\ 0.0276 & -0.0490 & -0.0357 & 0.0571 \\ 0.0082 & -0.0276 & 0.0143 & 0.0051 \end{pmatrix}$$

3.3.2 Étape 2 : Calcul de la matrice $\mathbf{Z}$

$$\mathbf{Z} = \mathbf{D}_r^{-1/2}(\mathbf{P} - \mathbf{rc}^T)\mathbf{D}_c^{-1/2}$$

Après calcul, on obtient :

$$\mathbf{Z} \approx \begin{pmatrix} -0.101 & 0.296 & 0.080 & -0.250 \\ -0.017 & 0.022 & -0.000 & 0.000 \\ 0.113 & -0.239 & -0.149 & 0.239 \\ 0.042 & -0.150 & 0.082 & 0.033 \end{pmatrix}$$

3.3.3 Étape 3 : Décomposition en valeurs singulières (SVD)

La décomposition en valeurs singulières de $\mathbf{Z}$ donne :

$$\mathbf{Z} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^T$$

Les valeurs singulières sont :

$$\lambda_1 = 0.384, \quad \lambda_2 = 0.182, \quad \lambda_3 = 0.075$$

La part d'inertie expliquée par chaque axe est :

$$\text{— Axe 1 : } \frac{\lambda_1^2}{\sum \lambda_k^2} = \frac{0.1475}{0.1902} = 77.5\%$$

$$\text{— Axe 2 : } \frac{\lambda_2^2}{\sum \lambda_k^2} = \frac{0.0331}{0.1902} = 17.4\%$$

$$\text{— Axe 3 : } \frac{\lambda_3^2}{\sum \lambda_k^2} = \frac{0.0056}{0.1902} = 2.9\%$$

Les deux premiers axes expliquent 94.9% de l'inertie totale.

3.3.4 Étape 4 : Coordonnées factorielles

Les coordonnées des lignes sur les axes factoriels sont :

$$\mathbf{F} = \mathbf{D}_r^{-1/2}\mathbf{U}\mathbf{\Lambda}$$

Les coordonnées des colonnes sur les axes factoriels sont :

$$\mathbf{G} = \mathbf{D}_c^{-1/2}\mathbf{V}\mathbf{\Lambda}$$

TABLE 4 – Coordonnées factorielles des lignes (âges)

Âge	Axe 1	Axe 2
15-25 ans	-0.438	0.571
26-40 ans	-0.059	0.015
41-60 ans	0.507	-0.407
61+ ans	0.766	0.473

TABLE 5 – Coordonnées factorielles des colonnes (genres musicaux)

Genre	Axe 1	Axe 2
Classique	0.556	0.366
Rock	-0.801	0.555
Pop	-0.291	-0.619
Jazz	0.378	-0.269

3.3.5 Étape 5 : Contributions et cosinus carrés

TABLE 6 – Contributions des points lignes à l'inertie des axes

Âge	Contr. axe 1	Contr. axe 2	Cos ² axe 1	Cos ² axe 2
15-25 ans	15.2%	36.8%	0.37	0.63
26-40 ans	0.3%	0.0%	0.94	0.06
41-60 ans	22.1%	18.2%	0.61	0.39
61+ ans	62.4%	45.0%	0.72	0.28

4 Interprétation des résultats

4.1 Représentation graphique

4.2 Interprétation des axes

4.2.1 Axe 1 (77.5% de l'inertie)

L'axe 1 oppose :

- À droite (coordonnées positives) : les personnes âgées (41-60 ans et 61+ ans) et le genre classique
- À gauche (coordonnées négatives) : les jeunes (15-25 ans) et le rock

Cet axe représente donc un gradient d'âge opposant les préférences pour la musique classique (personnes âgées) au rock (jeunes).




FIGURE 1 – Plan factoriel 1-2 de l'AFC

4.2.2 Axe 2 (17.4% de l'inertie)

L'axe 2 oppose :

- En haut (coordonnées positives) : les extrêmes d'âge (15-25 ans et 61+ ans) avec le rock et le classique
- En bas (coordonnées négatives) : la tranche d'âge 41-60 ans avec la pop

Cet axe semble distinguer les genres musicaux plus "traditionnels" (classique, jazz) des genres plus "modernes" (rock, pop).

4.3 Synthèse

L'AFC révèle une structure claire dans les données :

- Les jeunes (15-25 ans) préfèrent le rock et la pop
- Les personnes d'âge moyen (26-40 ans) ont des goûts éclectiques sans préférence marquée
- Les personnes âgées (41-60 ans et 61+ ans) préfèrent la musique classique et le jazz
- Le rock est particulièrement associé aux jeunes (15-25 ans)
- La musique classique est particulièrement associée aux personnes âgées (61+ ans)

5 Implémentation avec R et Python

5.1 Implémentation avec R

```

1      # Charger les données
2      donnees <- matrix(c(10, 35, 30, 5,
3                          15, 20, 25, 20,
```



```
4      25, 5, 10, 25,
5      30, 0, 5, 20),
6      nrow = 4, byrow = TRUE,
7      dimnames = list(c("15-25 ans", "26-40 ans",
8      "41-60 ans", "61+ ans"),
9      c("Classique", "Rock",
10     "Pop", "Jazz")))
11
12     # AFC avec FactoMineR
13     library(FactoMineR)
14     resultat_afc <- CA(donnees, graph = TRUE)
15
16     # Résumé des résultats
17     summary(resultat_afc)
18
19     # Graphique des contributions
20     library(factoextra)
21     fviz_ca_biplot(resultat_afc, repel = TRUE)
22     fviz_contrib(resultat_afc, choice = "row", axes =
23     1:2)
24     fviz_contrib(resultat_afc, choice = "col", axes =
25     1:2)
```

5.2 Implémentation avec Python

```
1      import pandas as pd
2      import numpy as np
3      from sklearn.decomposition import CA
4      import matplotlib.pyplot as plt
5
6      # Création du tableau de données
7      data = pd.DataFrame({
8          'Classique': [10, 15, 25, 30],
9          'Rock': [35, 20, 5, 0],
10         'Pop': [30, 25, 10, 5],
11         'Jazz': [5, 20, 25, 20]
12     }, index=['15-25 ans', '26-40 ans', '41-60 ans',
13             '61+ ans'])
14
15     # Application de l'AFC
16     ca = CA(n_components=2)
```

```
16         ca.fit(data)
17
18     # Coordonnées factorielles
19     row_coords = ca.row_coordinates(data)
20     col_coords = ca.column_coordinates(data)
21
22     # Graphique
23     fig, ax = plt.subplots(figsize=(10, 8))
24
25     # Points lignes
26     for i, txt in enumerate(row_coords.index):
27         ax.scatter(row_coords.iloc[i, 0], row_coords.iloc
28                    [i, 1],
29                    color='blue', s=100)
30         ax.annotate(txt, (row_coords.iloc[i, 0],
31                           row_coords.iloc[i, 1]),
32                       xytext=(5, 5), textcoords='offset points')
33
34     # Points colonnes
35     for i, txt in enumerate(col_coords.index):
36         ax.scatter(col_coords.iloc[i, 0], col_coords.iloc
37                    [i, 1],
38                    color='red', s=100, marker='s')
39         ax.annotate(txt, (col_coords.iloc[i, 0],
40                           col_coords.iloc[i, 1]),
41                       xytext=(5, 5), textcoords='offset points')
42
43     ax.axhline(y=0, color='gray', linestyle='--',
44                alpha=0.5)
45     ax.axvline(x=0, color='gray', linestyle='--',
46                alpha=0.5)
47     ax.set_xlabel('Axe 1')
48     ax.set_ylabel('Axe 2')
49     ax.set_title('Plan factoriel 1-2')
50     plt.grid(True, alpha=0.3)
51     plt.show()
```

6 Conclusion

L'Analyse Factorielle des Correspondances est une méthode puissante pour explorer les relations entre deux variables qualitatives. À travers notre exemple, nous avons montré comment :

1. **Préparer les données** : construire un tableau de contingence 2. **Calculer les indicateurs** : profils, masses, écarts à l'indépendance 3. **Réaliser l'AFC** : décomposition en valeurs singulières, coordonnées factorielles 4. **Interpréter les résultats** : analyse des axes, contributions, représentation graphique 5. **Implémenter l'analyse** avec R ou Python

L'AFC permet de visualiser dans un espace réduit les associations entre modalités et d'identifier les structures sous-jacentes dans les données. Elle est particulièrement utile pour l'exploration initiale de données catégorielles et la formulation d'hypothèses.

7 Références

1. Benzécri, J.P. (1973). *L'analyse des données. Tome 1 : La taxinomie. Tome 2 : L'analyse des correspondances*. Dunod.
2. Lebart, L., Morineau, A., & Piron, M. (1995). *Statistique exploratoire multidimensionnelle*. Dunod.
3. Husson, F., Lê, S., & Pagès, J. (2017). *Exploratory Multivariate Analysis by Example Using R*. CRC Press.
4. Greenacre, M. (2017). *Correspondence Analysis in Practice*. CRC Press.
5. Abdi, H., & Williams, L.J. (2010). Correspondence analysis. In *Encyclopedia of Research Design*. SAGE Publications.

A Annexe : Formules complètes

A.1 Inertie totale

L'inertie totale du nuage des profils lignes (ou colonnes) est donnée par :

$$\text{Inertie totale} = \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j} = \sum_{k=1}^K \lambda_k^2$$

Cette inertie est égale au χ^2 de l'analyse divisé par n :

$$\text{Inertie} = \frac{\chi^2}{n}$$

A.2 Test du chi-deux

Avant de réaliser une AFC, il est recommandé de tester l'indépendance entre les variables avec un test du chi-deux :

$$\chi^2 = n \sum_{i=1}^I \sum_{j=1}^J \frac{(p_{ij} - r_i c_j)^2}{r_i c_j}$$

Dans notre exemple : $\chi^2 = 280 \times 0.1902 = 53.26$

Avec $(I-1)(J-1) = 3 \times 3 = 9$ degrés de liberté, cette valeur est hautement significative ($p < 0.001$), justifiant la poursuite de l'analyse.