

Cours de Régression Linéaire Simple avec Exemples Pratiques

DUT : GI-SIR-IDIA / ESTBM USMS

Pr. Abdelaziz QAFFOU

Résumé

Ce document présente une introduction à la régression linéaire simple. Nous abordons le modèle mathématique, l'estimation des paramètres par la méthode des moindres carrés ordinaires, les tests d'hypothèses et des exemples pratiques avec interprétation des résultats. Des implémentations en Python sont fournies pour illustrer les concepts.

Table des matières

1	Introduction	2
2	Le Modèle de Régression Linéaire Simple	2
2.1	Formulation du modèle	2
2.2	Hypothèses du modèle	3
3	Estimation des Paramètres	3
3.1	Méthode des Moindres Carrés Ordinaires (MCO)	3
3.2	Formules des estimateurs	3
3.3	Estimation de la variance des erreurs	4
4	Propriétés des Estimateurs MCO	4
5	Tests d'Hypothèses et Intervalles de Confiance	4
5.1	Test sur le coefficient de pente	4
5.2	Intervalles de confiance	4
6	Analyse de la Variance (ANOVA)	5
6.1	Coefficient de détermination	5

7 Exemples Pratiques	5
7.1 Exemple 1 : Relation entre taille et poids	5
7.1.1 Données	5
7.1.2 Calculs manuels	5
7.1.3 Interprétation	6
7.2 Exemple 2 : Implémentation en Python	6
7.2.1 Résultats attendus	9
8 Validation du Modèle	9
8.1 Analyse des résidus	9
8.2 Mesures d'influence	9
9 Conclusion	10
A Annexe : Dérivation des Estimateurs MCO	10
B Références	11

1 Introduction

La régression linéaire simple est une méthode statistique fondamentale utilisée pour modéliser la relation entre deux variables quantitatives. Elle permet de :

- Décrire la relation entre une variable explicative (indépendante) X et une variable réponse (dépendante) Y
- Prédire les valeurs de Y pour de nouvelles valeurs de X
- Quantifier la force de la relation linéaire entre X et Y

2 Le Modèle de Régression Linéaire Simple

2.1 Formulation du modèle

Le modèle de régression linéaire simple s'écrit :

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n$$

où :

- Y_i est la variable réponse (dépendante) pour l'observation i
- X_i est la variable explicative (indépendante) pour l'observation i
- β_0 est l'ordonnée à l'origine (intercept)
- β_1 est la pente (coefficient de régression)

— ε_i est le terme d'erreur aléatoire, avec $\mathbb{E}[\varepsilon_i] = 0$ et $\text{Var}(\varepsilon_i) = \sigma^2$

2.2 Hypothèses du modèle

Pour que les estimateurs des moindres carrés aient de bonnes propriétés, nous faisons les hypothèses suivantes :

1. **Linéarité** : La relation entre X et Y est linéaire
2. **Indépendance** : Les erreurs ε_i sont indépendantes
3. **Homoscédasticité** : Les erreurs ont une variance constante σ^2
4. **Normalité** : Les erreurs ε_i suivent une distribution normale

3 Estimation des Paramètres

3.1 Méthode des Moindres Carrés Ordinaires (MCO)

Les estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$ minimisent la somme des carrés des résidus :

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

3.2 Formules des estimateurs

Les estimateurs des moindres carrés sont donnés par :

$$\begin{aligned}\hat{\beta}_1 &= \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{S_{XY}}{S_{XX}} \\ \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X}\end{aligned}$$

où :

$$\begin{aligned}\bar{X} &= \frac{1}{n} \sum_{i=1}^n X_i, \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i \\ S_{XX} &= \sum_{i=1}^n (X_i - \bar{X})^2 \\ S_{XY} &= \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})\end{aligned}$$

3.3 Estimation de la variance des erreurs

La variance des erreurs σ^2 est estimée par :

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \frac{SCE}{n-2}$$

où SCE est la somme des carrés des erreurs et $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$.

4 Propriétés des Estimateurs MCO

Sous les hypothèses du modèle linéaire classique, les estimateurs MCO ont les propriétés suivantes :

1. **Non-biaisés** : $\mathbb{E}[\hat{\beta}_0] = \beta_0$ et $\mathbb{E}[\hat{\beta}_1] = \beta_1$
2. **BLUE** : Best Linear Unbiased Estimators (meilleurs estimateurs linéaires sans biais)
3. **Variances** :

$$\begin{aligned}\text{Var}(\hat{\beta}_0) &= \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}} \right) \\ \text{Var}(\hat{\beta}_1) &= \frac{\sigma^2}{S_{XX}}\end{aligned}$$

5 Tests d'Hypothèses et Intervalles de Confiance

5.1 Test sur le coefficient de pente

Pour tester $H_0 : \beta_1 = 0$ contre $H_1 : \beta_1 \neq 0$, on utilise la statistique :

$$t = \frac{\hat{\beta}_1}{\widehat{\text{se}}(\hat{\beta}_1)} \sim t_{n-2} \quad \text{sous } H_0$$

où $\widehat{\text{se}}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{S_{XX}}}$ est l'erreur standard de $\hat{\beta}_1$.

5.2 Intervalles de confiance

L'intervalle de confiance à $100(1 - \alpha)\%$ pour β_1 est :

$$\hat{\beta}_1 \pm t_{n-2, 1-\alpha/2} \times \widehat{\text{se}}(\hat{\beta}_1)$$

De même pour β_0 :

$$\hat{\beta}_0 \pm t_{n-2, 1-\alpha/2} \times \widehat{\text{se}}(\hat{\beta}_0)$$

6 Analyse de la Variance (ANOVA)

Le tableau d'ANOVA pour la régression linéaire simple se présente comme suit :

Source	Somme des Carrés	ddl	Carrés Moyens	F	p-valeur
Régression	$SCR = \sum (\hat{Y}_i - \bar{Y})^2$	1	$CMR = SCR$	CMR/CME	$P(F_{1,n-2} >$
Erreur	$SCE = \sum (Y_i - \hat{Y}_i)^2$	$n - 2$	$CME = SCE/(n - 2)$		
Total	$SCT = \sum (Y_i - \bar{Y})^2$	$n - 1$			

TABLE 1 – Tableau d'ANOVA pour la régression linéaire simple

6.1 Coefficient de détermination

Le coefficient de détermination R^2 mesure la proportion de variance expliquée par le modèle :

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}$$

R^2 varie entre 0 et 1. Plus R^2 est proche de 1, meilleur est l'ajustement du modèle.

7 Exemples Pratiques

7.1 Exemple 1 : Relation entre taille et poids

Supposons que nous voulons étudier la relation entre la taille (en cm) et le poids (en kg) d'un groupe d'étudiants.

7.1.1 Données

7.1.2 Calculs manuels

Calculons les estimateurs MCO :

Taille (X)	Poids (Y)
160	55
165	60
170	65
175	70
180	75
185	80
190	85

TABLE 2 – Données taille-poids

$$\begin{aligned}
n &= 7 \\
\bar{X} &= \frac{160 + 165 + \dots + 190}{7} = 175 \\
\bar{Y} &= \frac{55 + 60 + \dots + 85}{7} = 70 \\
S_{XX} &= \sum (X_i - \bar{X})^2 = 525 \\
S_{XY} &= \sum (X_i - \bar{X})(Y_i - \bar{Y}) = 525 \\
\hat{\beta}_1 &= \frac{S_{XY}}{S_{XX}} = \frac{525}{525} = 1 \\
\hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X} = 70 - 1 \times 175 = -105
\end{aligned}$$

L'équation de la droite de régression est donc :

$$\hat{Y} = -105 + 1 \times X$$

7.1.3 Interprétation

- La pente $\hat{\beta}_1 = 1$ signifie qu'une augmentation de 1 cm de taille est associée à une augmentation de 1 kg du poids.
- L'ordonnée à l'origine $\hat{\beta}_0 = -105$ n'a pas d'interprétation pratique dans ce cas (poids négatif pour taille nulle).

7.2 Exemple 2 : Implémentation en Python

Voici un exemple complet d'implémentation de la régression linéaire simple en Python :

```

1      import numpy as np
2      import matplotlib.pyplot as plt
3      from scipy import stats
4
5      # Données d'exemple : heures d'étude vs
6      # note à l'examen
7      X = np.array([1, 2, 3, 4, 5, 6, 7, 8, 9,
8                    10]) # heures d'étude
9      Y = np.array([55, 60, 65, 70, 75, 80,
10                   85, 90, 95, 100]) # note
11
12     # Calcul des statistiques descriptives
13     n = len(X)
14     mean_X = np.mean(X)
15     mean_Y = np.mean(Y)
16
17     # Calcul des estimateurs MCO
18     S_XX = np.sum((X - mean_X) ** 2)
19     S_XY = np.sum((X - mean_X) * (Y - mean_Y
20                    ))
21
22     beta_1 = S_XY / S_XX
23     beta_0 = mean_Y - beta_1 * mean_X
24
25     print(f"Équation de la droite: Y = {
26           beta_0:.2f} + {beta_1:.2f}X")
27
28     # Prédiction
29     Y_pred = beta_0 + beta_1 * X
30
31     # Calcul des résidus
32     residuals = Y - Y_pred
33
34     # Estimation de la variance des erreurs
35     sigma2 = np.sum(residuals ** 2) / (n -
36           2)
37     print(f"Estimation de la variance des
38           erreurs: {sigma2:.2f}")
39
40     # Calcul de R^2
41     SST = np.sum((Y - mean_Y) ** 2)
42     SSR = np.sum((Y_pred - mean_Y) ** 2)

```

```

36     SSE = np.sum(residuals ** 2)
37     R2 = SSR / SST
38     print(f"Coefficient de détermination R
      ^2: {R2:.4f}")
39
40     # Tests d'hypothèses sur beta_1
41     se_beta1 = np.sqrt(sigma2 / S_XX)
42     t_stat = beta_1 / se_beta1
43     p_value = 2 * (1 - stats.t.cdf(np.abs(
      t_stat), df=n-2))
44     print(f"Statistique t pour beta_1: {
      t_stat:.4f}")
45     print(f"p-valeur: {p_value:.6f}")
46
47     # Intervalle de confiance à 95% pour
      beta_1
48     t_critical = stats.t.ppf(0.975, df=n-2)
49     CI_lower = beta_1 - t_critical *
      se_beta1
50     CI_upper = beta_1 + t_critical *
      se_beta1
51     print(f"IC 95% pour beta_1: [{CI_lower
      :.4f}, {CI_upper:.4f}]")
52
53     # Visualisation
54     plt.figure(figsize=(10, 6))
55     plt.scatter(X, Y, color='blue', label='
      Données observées')
56     plt.plot(X, Y_pred, color='red', label=f
      'Droite de régression: Y = {beta_0:.2
      f} + {beta_1:.2f}X')
57     plt.xlabel('Heures d\'étude')
58     plt.ylabel('Note à l\'examen')
59     plt.title('Régression linéaire: Heures d
      \'étude vs Note')
60     plt.legend()
61     plt.grid(True, alpha=0.3)
62     plt.show()
63
64     # Diagramme des résidus
65     plt.figure(figsize=(10, 6))
66     plt.scatter(Y_pred, residuals, color='
      green')

```



```

67         plt.axhline(y=0, color='red', linestyle=
        '--')
68         plt.xlabel('Valeurs prédites')
69         plt.ylabel('Résidus')
70         plt.title('Diagramme des résidus')
71         plt.grid(True, alpha=0.3)
72         plt.show()

```

Listing 1 – Régression linéaire simple en Python

7.2.1 Résultats attendus

Pour cet exemple, les résultats devraient être approximativement :

- Équation : $Y = 50 + 5X$
- $R^2 \approx 1$ (relation linéaire parfaite dans ces données artificielles)
- p-valeur pour β_1 très petite (< 0.05), indiquant que la pente est significativement différente de zéro

8 Validation du Modèle

Après l'estimation du modèle, il est essentiel de vérifier les hypothèses :

8.1 Analyse des résidus

Les résidus $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$ doivent être examinés pour :

1. **Indépendance** : Graphique des résidus vs. l'ordre des observations
2. **Homoscédasticité** : Graphique des résidus vs. les valeurs prédites
3. **Normalité** : Histogramme ou QQ-plot des résidus

8.2 Mesures d'influence

Certaines observations peuvent avoir un impact disproportionné sur les résultats :

- **Points leviers** : Observations avec des valeurs extrêmes de X
- **Points atypiques** : Observations avec de grands résidus
- **Points influents** : Observations qui modifient significativement les estimations lorsqu'elles sont retirées

9 Conclusion

La régression linéaire simple est un outil puissant pour :

- Décrire les relations linéaires entre variables
- Effectuer des prédictions
- Tester des hypothèses sur les relations entre variables

Cependant, il est crucial de :

1. Vérifier les hypothèses du modèle
2. Interpréter les résultats avec prudence
3. Considérer d'autres modèles si la relation n'est pas linéaire

Exercices

1. Pour les données suivantes, calculez l'équation de la droite de régression :

X	Y
1	2
2	4
3	5
4	4
5	6

2. Interprétez les coefficients β_0 et β_1 dans le contexte suivant : Y est le prix d'une maison (en milliers d'euros) et X est sa surface (en m²). L'équation estimée est : $\hat{Y} = 50 + 3X$.
3. Implémentez en Python une fonction qui calcule les estimateurs MCO sans utiliser de bibliothèque de régression.

A Annexe : Dérivation des Estimateurs MCO

Pour trouver les estimateurs MCO, on minimise :

$$S(\beta_0, \beta_1) = \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2$$

Les conditions de premier ordre :

$$\begin{aligned}\frac{\partial S}{\partial \beta_0} &= -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i) = 0 \\ \frac{\partial S}{\partial \beta_1} &= -2 \sum_{i=1}^n X_i (Y_i - \beta_0 - \beta_1 X_i) = 0\end{aligned}$$

Ce système d'équations conduit aux estimateurs donnés en section [3](#).

B Références

Références

- [1] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to Linear Regression Analysis*. Wiley.
- [2] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer.
- [3] Francq, C. & Govaerts, B. (2014). *Modèles linéaires en statistique*. Ellipses.