

Test d'indépendance du Khi-deux

DUT : GI-SIR-IDIA / ESTBM USMS

Pr. Abdelaziz QAFFOU

1 Introduction

Le test d'indépendance du Khi-deux (noté χ^2) est un test statistique non paramétrique utilisé pour déterminer s'il existe une relation significative entre deux variables qualitatives (catégorielles). Il permet de tester l'hypothèse nulle d'indépendance entre ces deux variables.

2 Contexte d'utilisation

On utilise le test du Khi-deux d'indépendance dans les situations suivantes :

- Les deux variables sont qualitatives (nominales ou ordinales)
- Les données sont présentées sous forme de tableau de contingence
- Les effectifs théoriques sont suffisamment grands (généralement 5 par case)

3 Hypothèses du test

Hypothèse nulle (H_0) : Les deux variables sont indépendantes. Il n'existe pas de relation entre elles.

Hypothèse alternative (H_1) : Les deux variables sont dépendantes. Il existe une relation significative entre elles.

4 Tableau de contingence

Soit un tableau de contingence croisant deux variables :

- Variable X avec r modalités (lignes)
- Variable Y avec c modalités (colonnes)

TABLE 1 – Structure d'un tableau de contingence $r \times c$

	Y_1	Y_2	$\cdots$	Y_c	Total
X_1	n_{11}	n_{12}	$\cdots$	n_{1c}	$n_{1.}$
X_2	n_{21}	n_{22}	$\cdots$	n_{2c}	$n_{2.}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
X_r	n_{r1}	n_{r2}	$\cdots$	n_{rc}	$n_{r.}$
Total	$n_{.1}$	$n_{.2}$	$\cdots$	$n_{.c}$	n

Où :

- n_{ij} : effectif observé dans la cellule (i, j)
- $n_{i\cdot}$: total de la ligne i
- $n_{\cdot j}$: total de la colonne j
- n : effectif total

5 Statistique du test

La statistique du Khi-deux est calculée comme suit :

$$\chi_{\text{obs}}^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - e_{ij})^2}{e_{ij}} \quad (1)$$

Où e_{ij} est l'effectif théorique sous l'hypothèse d'indépendance, calculé par :

$$e_{ij} = \frac{n_{i\cdot} \times n_{\cdot j}}{n} \quad (2)$$

6 Degrés de liberté

Le nombre de degrés de liberté pour le test est :

$$\text{ddl} = (r - 1) \times (c - 1) \quad (3)$$

7 Conditions d'application

Pour que le test soit valide, il faut respecter les conditions suivantes :

1. Les observations sont indépendantes
2. Les effectifs théoriques e_{ij} doivent être :
 - Au moins 80% des $e_{ij} \geq 5$
 - Tous les $e_{ij} > 1$

Si ces conditions ne sont pas remplies, on peut :

- Regrouper des modalités
- Utiliser le test exact de Fisher (pour les petits effectifs)

8 Règle de décision

1. On choisit un risque d'erreur α (généralement 5%)
2. On détermine la valeur critique χ_{crit}^2 dans la table du Khi-deux avec ddl degrés de liberté
3. Règle de décision :
 - Si $\chi_{\text{obs}}^2 > \chi_{\text{crit}}^2$: on rejette H_0
 - Sinon : on ne rejette pas H_0

On peut également utiliser la p-valeur :

- Si p-valeur $< \alpha$: on rejette H_0
- Sinon : on ne rejette pas H_0

9 Exemple concret

Exemple 1. Une étude cherche à déterminer s'il existe un lien entre le niveau d'études (Bac, Licence, Master) et la pratique d'une activité sportive (Oui, Non). On a collecté les données suivantes auprès de 200 personnes :

TABLE 2 – Tableau observé

	Sportif	Non-sportif	Total
Bac	30	40	70
Licence	45	35	80
Master	35	15	50
Total	110	90	200

Étape 1 : Calcul des effectifs théoriques Par exemple, pour la cellule (Bac, Sportif) :

$$e_{11} = \frac{70 \times 110}{200} = 38.5$$

On calcule tous les effectifs théoriques :

TABLE 3 – Tableau des effectifs théoriques

	Sportif	Non-sportif
Bac	38.5	31.5
Licence	44.0	36.0
Master	27.5	22.5

Étape 2 : Calcul de la statistique χ^2

$$\begin{aligned}
 \chi_{obs}^2 &= \frac{(30 - 38.5)^2}{38.5} + \frac{(40 - 31.5)^2}{31.5} + \frac{(45 - 44)^2}{44} \\
 &\quad + \frac{(35 - 36)^2}{36} + \frac{(35 - 27.5)^2}{27.5} + \frac{(15 - 22.5)^2}{22.5} \\
 &= 1.87 + 2.28 + 0.02 + 0.03 + 2.05 + 2.50 \\
 &= 8.75
 \end{aligned}$$

Étape 3 : Degrés de liberté

$$ddl = (3 - 1) \times (2 - 1) = 2$$

Étape 4 : Décision Pour $\alpha = 0.05$ et $ddl = 2$, la valeur critique est $\chi_{crit}^2 = 5.99$.

Comme $\chi_{obs}^2 = 8.75 > 5.99$, on rejette l'hypothèse nulle d'indépendance.

Il existe donc une relation significative entre le niveau d'études et la pratique sportive.

10 Interprétation des résultats

- Le test indique seulement s'il existe une relation, pas sa nature
- Pour comprendre la nature de la relation, on peut :
 - Analyser les résidus standardisés
 - Examiner graphiquement les écarts entre observés et théoriques
 - Calculer les odds-ratios pour les tableaux 2E2

11 Limitations et précautions

1. Le test ne mesure pas l'intensité de la relation, seulement son existence
2. Il est sensible à la taille de l'échantillon
3. Il ne donne pas la direction de la relation
4. Attention aux effectifs trop faibles (risque d'erreur de type II)

12 Extensions du test

Test d'homogénéité : Même calcul mais interprétation différente

Test d'adéquation : Comparaison à une distribution théorique

Correction de Yates : Pour les tableaux 2E2 avec petits effectifs

Test exact de Fisher : Alternative pour petits échantillons

13 Conclusion

Le test d'indépendance du Khi-deux est un outil fondamental en statistique pour analyser les relations entre variables catégorielles. Sa mise en uvre est relativement simple, mais nécessite une attention particulière aux conditions d'application et à l'interprétation des résultats.

A Table du Khi-deux (extrait)

TABLE 4 – Valeurs critiques du χ^2 pour $\alpha = 0.05$

Degrés de liberté	χ^2_{crit}
1	3.84
2	5.99
3	7.81
4	9.49
5	11.07
6	12.59