

TP : Régression linéaire simple

DUT : GI-SIR-IDIA / ESTBM USMS

Pr. Abdelaziz QAFFOU

Objectifs

Ce TP a pour but d'analyser la relation entre deux variables quantitatives (X et Y) à l'aide d'un modèle de régression linéaire simple :

- de comprendre les hypothèses du modèle linéaire ;
- d'estimer les paramètres du modèle par la méthode des moindres carrés ordinaires (MCO) ;
- de réaliser une régression linéaire à l'aide d'un logiciel (R ou Python) ;
- d'interpréter les coefficients, la qualité de l'ajustement (R^2) et les résidus.

1 Données

On considère un jeu de données portant sur les ventes de glaces (*Sales*, en milliers d'unités) en fonction de la température extérieure moyenne (*Temperature*, en degrés Celsius) observée sur 12 jours différents.

Le but est de modéliser l'impact de la température sur les ventes.

TABLE 1 – Données de ventes de glaces vs Température

Jour	Température (°C)	Ventes (k unités)
1	14.2	215.2
2	16.4	325.0
3	11.9	185.9
4	15.2	330.1
5	18.5	460.1
6	22.1	520.0
7	19.4	450.2
8	25.1	610.1
9	23.4	490.5
10	18.1	410.2
11	22.6	470.2
12	17.2	360.5

2 Questions

2.1 Exploration des données et Hypothèses

1. Identifier la variable explicative (X , indépendante) et la variable à expliquer (Y , dépendante).
2. Tracer un nuage de points (diagramme de dispersion) de Y en fonction de X .
3. À partir du graphique, l'hypothèse de **linéarité** semble-t-elle raisonnable ?
4. Calculer le coefficient de corrélation linéaire de Pearson entre la Température et les Ventes. Interpréter ce résultat.

2.2 Modélisation et Interprétation

1. Estimer les paramètres du modèle de régression linéaire simple : $Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$ par la méthode des Moindres Carrés Ordinaires (MCO).
2. Écrire l'équation de la droite de régression estimée.
3. Interpréter la valeur du coefficient $\hat{\beta}_1$ (la pente) dans le contexte métier (ventes de glaces).
4. Calculer et interpréter le coefficient de détermination R^2 . Quelle proportion de la variance des ventes est expliquée par la température ?
5. Prédire le volume de ventes si la température atteint 20°C.

2.3 Validation du Modèle (Résidus)

1. Représenter graphiquement les résidus (ϵ_i) en fonction des valeurs prédites ($\hat{Y}_i$).
2. Les hypothèses sur les erreurs (ϵ_i) sont-elles respectées (homoscédasticité, non-corrélation) ? Justifier visuellement.

3 Code R (exemple)

```
1      # Création du Data Frame
2      data <- data.frame(
3      Temperature = c(14.2, 16.4, 11.9, 15.2, 18.5, 22.1, 19.4,
4      25.1, 23.4, 18.1, 22.6, 17.2),
5      Sales = c(215.2, 325.0, 185.9, 330.1, 460.1, 520.0, 450.2,
6      610.1, 490.5, 410.2, 470.2, 360.5)
7      )
8
9      # Nuage de points
10     plot(data$Temperature, data$Sales, main="Ventes vs
11     Température",
12     xlab="Température (°C)", ylab="Ventes (k)")
13
14     # Estimation du modèle linéaire (Sales en fonction de
15     Temperature)
16     modele_reg <- lm(Sales ~ Temperature, data=data)
17
18     # Affichage du résumé statistique complet (coefficients, R2,
19     p-values)
20     summary(modele_reg)
21
22     # Ajout de la droite de régression sur le graphique
23     abline(modele_reg, col="red")
```

Listing 1 – Code R pour la régression linéaire simple

4 Code Python (exemple)

```
1      import pandas as pd
2      import matplotlib.pyplot as plt
3      import statsmodels.api as sm
4      import seaborn as sns
5
6      # Création du DataFrame
7      data = pd.DataFrame({
8      'Temperature': [14.2, 16.4, 11.9, 15.2, 18.5, 22.1,
9      19.4, 25.1, 23.4, 18.1, 22.6, 17.2],
```

```

9         'Sales': [215.2, 325.0, 185.9, 330.1, 460.1, 520.0,
10                450.2, 610.1, 490.5, 410.2, 470.2, 360.5]
11     })
12
13     # Nuage de points
14     sns.scatterplot(x='Temperature', y='Sales', data=data)
15     plt.title("Ventes vs Température")
16     plt.show()
17
18     # Définition des variables X et Y pour statsmodels
19     X = sm.add_constant(data['Temperature']) # Ajoute la
20         constante (intercept)
21     Y = data['Sales']
22
23     # Estimation du modèle
24     modele_reg = sm.OLS(Y, X).fit()
25
26     # Affichage du résumé statistique complet
27     print(modele_reg.summary())
28
29     # Prédiction pour 20 degrés Celsius
30     temp_pred = pd.DataFrame({'Temperature': [20]})
31     temp_pred = sm.add_constant(temp_pred)
32     prediction = modele_reg.predict(temp_pred)
33     print(f"\nPrédiction pour 20°C: {prediction.values[0]:.2f} k
34           unités")

```

Listing 2 – Code Python pour la régression linéaire simple